Statistik

Diskrete Zufallsvariablen und Verteilungen

DSI Data Science Institute

Inhaltsverzeichnis

1. Grundbegriffe
2. Diskrete Gleichverteilung
3. Geometrische Verteilung
4. Verteilungskennzahlen
5. Binomialverteilung
6. Poisson-Verteilung

Lernziele

- Diskrete Zufallsvariablen, Wahrscheinlichkeitsfunktionen und Verteilungsfunktionen beschreiben sowie deren Bedeutung für die Modellierung zufälliger Prozesse erläutern.
- Erwartungswerte, Varianzen und Standardabweichungen diskreter Verteilungen berechnen und interpretieren.
- Diskrete Verteilungen unterscheiden, geeignete Modelle für praktische Fragestellungen auswählen und Wahrscheinlichkeiten damit bestimmen.

Grundbegriffe - Zufallsvariablen

Eine **Zufallsvariable** ist eine Funktion, die jedes Element des **Ergebnisraums** auf eine reelle Zahl abbildet.

$$X\colon \Omega \to \mathbb{R}$$

Die Zahl x, die X bei einer Durchführung des Zufallsvorgangs annimmt, heißt **Realisierung** oder Wert von X.

Beispiel:

$\Omega =$ „Eine Münze wird viermal geworfen“. $X = \text{"Anzahl von Kopf"}$. Für die Variable X sind die Werte $0, 1, 2, 3$ und 4 möglich, aber vor jedem neuen Wurf ist nicht sicher, welcher dieser Werte passiert wird.

Grundbegriffe - Wahrscheinlichkeitsverteilung

Eine Zufallsvariable X heißt **diskret**, falls sie nur endlich oder abzählbar unendlich viele Werte $x_1, x_1, \ldots, x_1, \ldots$ annehmen kann. Die **Wahrscheinlichkeitsverteilung** von X ist durch die Wahrscheinlichkeiten

$$P(X = x_i) = p_i, \qquad i = 1, 2, \ldots, k, \ldots,$$

gegeben.

Die **Wahrscheinlichkeitsfunktion** $f(x)$ einer diskreten Zufallsvariable X ist für $x \in \mathbb{R}$ definiert durch:

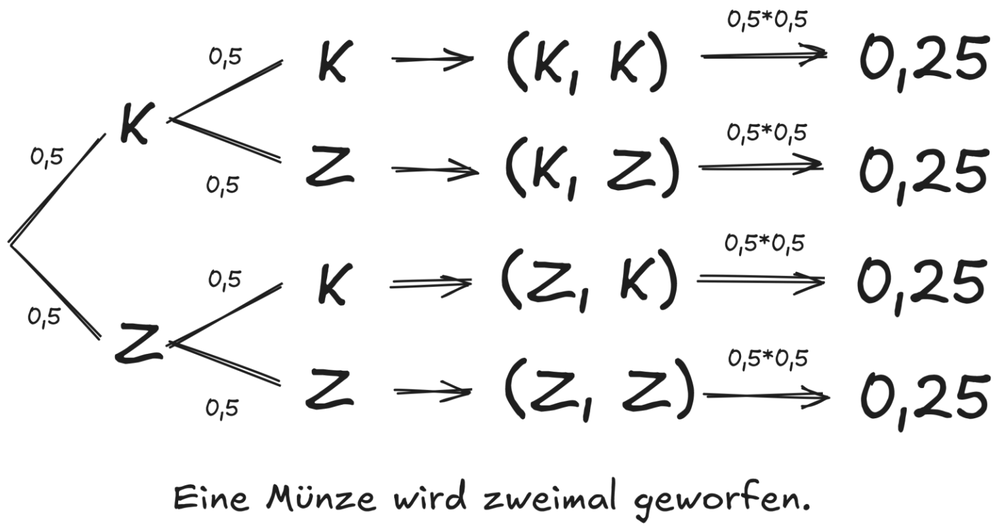
$$f(x) = \begin{cases} P(X = x_i) = p_i, & x_i \in x_1, x_2, \ldots, x_k, \ldots \\ 0, & \text{sonst} \end{cases}$$

Grundbegriffe - Verteilungsfunktion

Die **Verteilungsfunktion** einer diskreten Zufallsvariablen X ist die Funktion $F(x)$, die jeden Wert x_i der Variablen auf die Wahrscheinlichkeit abbildet:

$$F(x_i) = P(X \leq x_i) = f(x_1) + \cdots + f(x_i)$$

Beispiel: Eine Münze wird zweimal geworfen. $X = \{\text{"Anzahl von Kopf"}\}$.



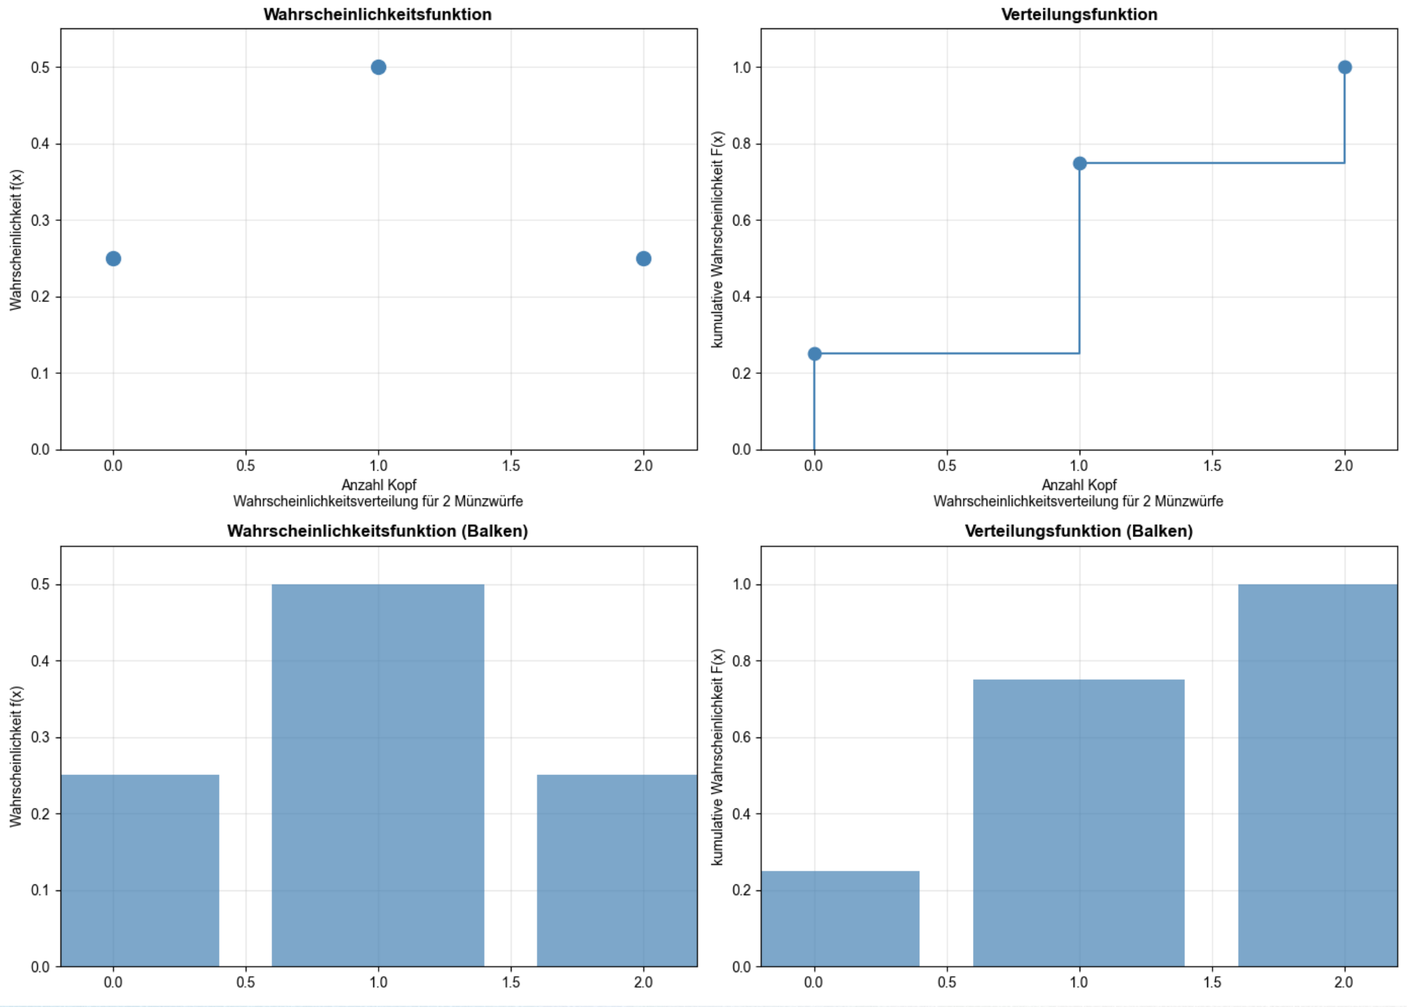
Eine Münze wird zweimal geworfen.

X	0	1	2
$f(x)$	0,25	0,5	0,25
$F(x)$	0,25	0,75	1

$$F(x) = \begin{cases} 0 & wenn \quad x < 0 \\ 0,25 & wenn \quad 0 \leq x < 1 \\ 0,75 & wenn \quad 1 \leq x < 2 \\ 1 & wenn \quad 2 \leq x \end{cases}$$

DSI Data Science Institute

Verteilungsfunktion - Beispiel

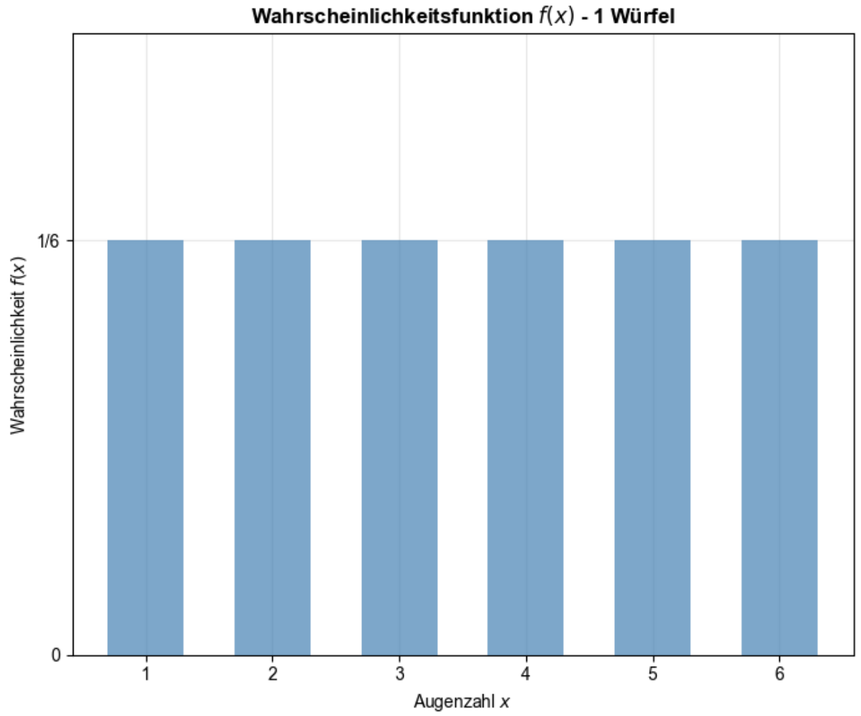


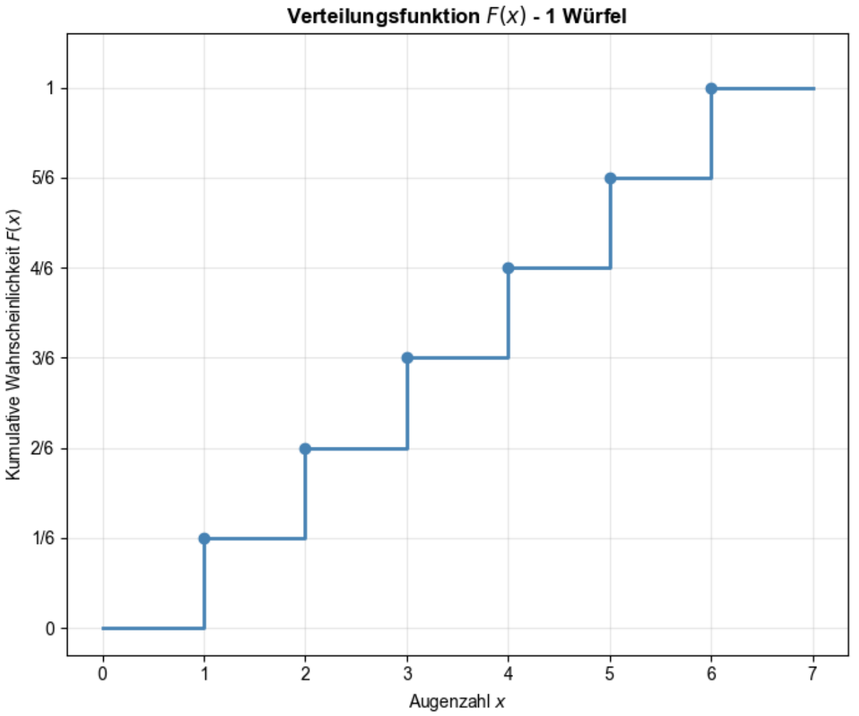
Data Science Institute

Verteilungsfunktion - Beispiel

Beim einmaligen Werfen eines Würfels definieren wir wie in die Zufallsvariable $X =$ "Augenzahl“.

x	1	2	3	4	5	6
$P(X = x)$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$



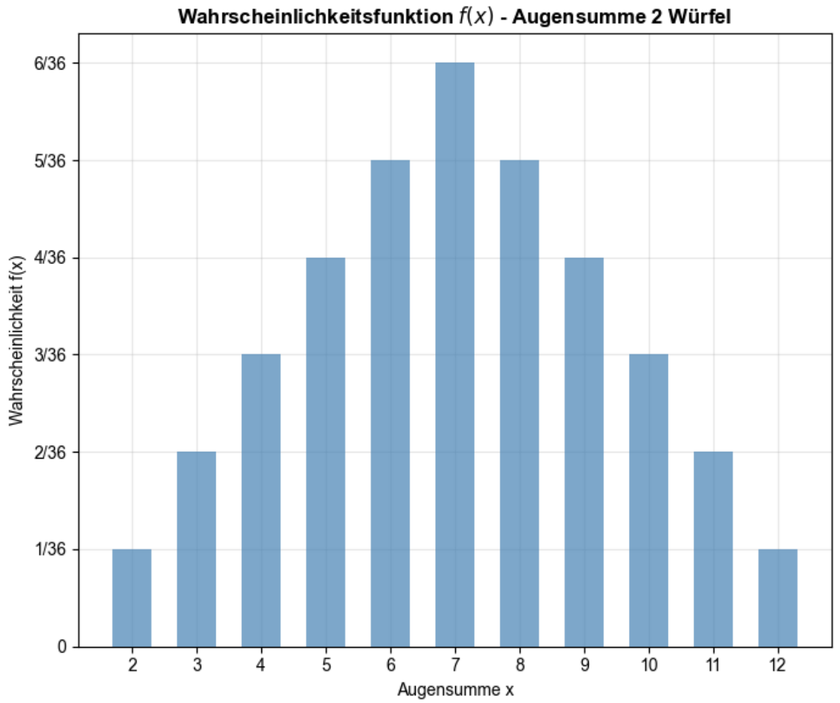


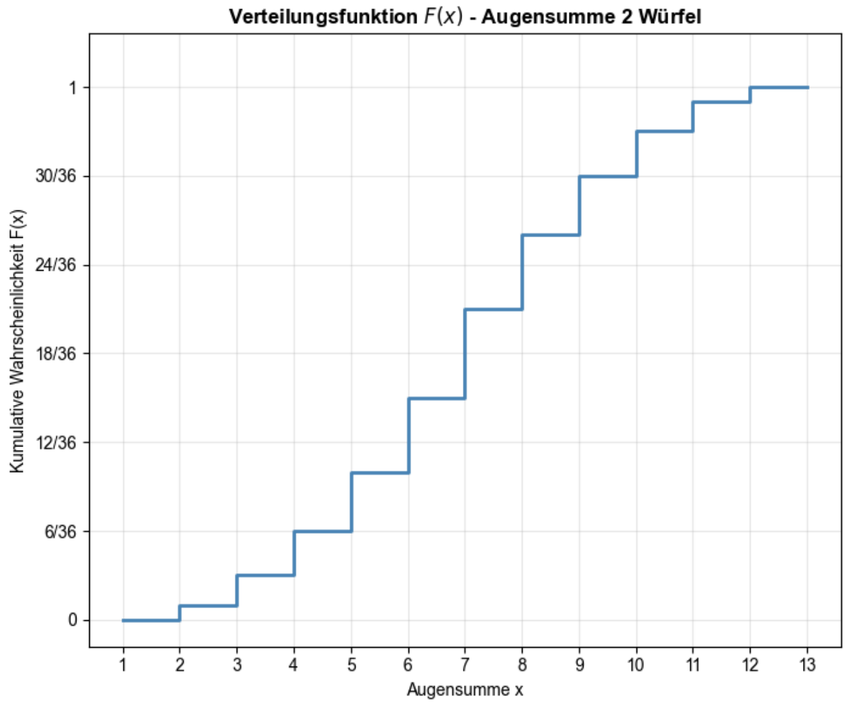
DSI Data Science Institute

Verteilungsfunktion - Beispiel

- Beim zweimaligen Werfen eines Würfels definieren wir wie in die Zufallsvariable $X =$ "Summe der Augenzahlen“.

x	2	3	4	5	6	7	8	9	10	11	12
$P(X = x)$	$\frac{1}{36}$	$\frac{2}{36}$	$\frac{3}{36}$	$\frac{4}{36}$	$\frac{5}{36}$	$\frac{6}{36}$	$\frac{5}{36}$	$\frac{4}{36}$	$\frac{3}{36}$	$\frac{2}{36}$	$\frac{1}{36}$





DSI Data Science Institute

Grundbegriffe - Bernoulli-Experiment

Beim Oft interessiert uns bei einem Zufallsvorgang nur eine einzige Frage: Tritt das Ereignis A ein oder nicht? Das ist der einfachste Fall der Statistik, auch bekannt als **Bernoulli-Experiment/-Versuch**.

Das Prinzip: Wir übersetzen das Ergebnis direkt in Zahlen. Die Zufallsvariable X dient dabei als Indikator:

- $X = 1$, falls das Ereignis A eintritt („Erfolg“)
- $X = 0$, falls das Ereignis A nicht eintritt („Misserfolg“)

Beispiele:

- Würfeln: Erziele ich eine gerade Augenzahl? $(Ja = 1, Nein = 0)$
- Medizin: Schlägt die Therapie bei einem Patienten an? $(Heilung = 1, keine\ Heilung = 0)$

Die Wahrscheinlichkeit (**Bernoulli-Verteilung**): Wenn wir die Wahrscheinlichkeit für den Erfolg mit "Pi" bezeichnen, sieht die Verteilung so aus:

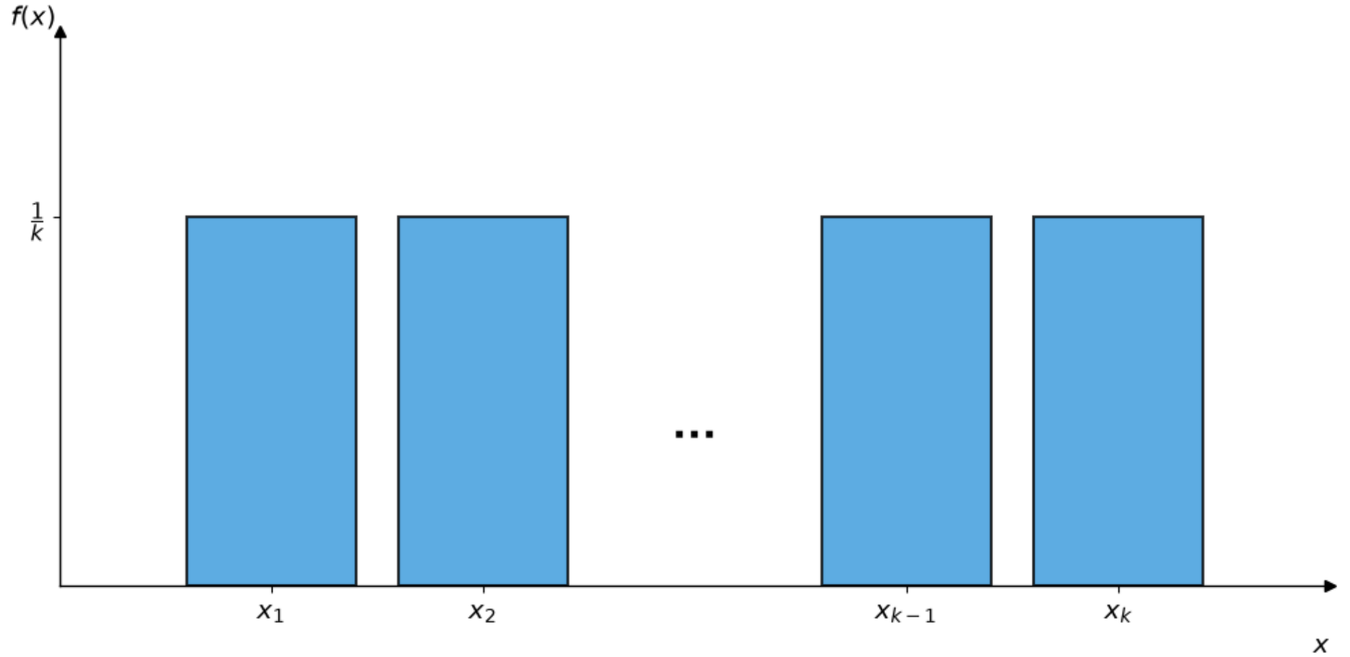
$$P(X = 1) = \pi$$
$$P(X = 0) = 1 - \pi$$

Diskrete Gleichverteilung

Eine diskrete Zufallsvariable X heißt gleichverteilt, wenn

$$P(X = x_i) = \frac{1}{\mathrm{k}}$$

Die Zufallsvariable Zufallsvariable $X =$ "Augenzahl“ beim einmaligen Würfeln ist ein einfaches Beispiel einer gleichverteilten diskreten Zufallsvariable.

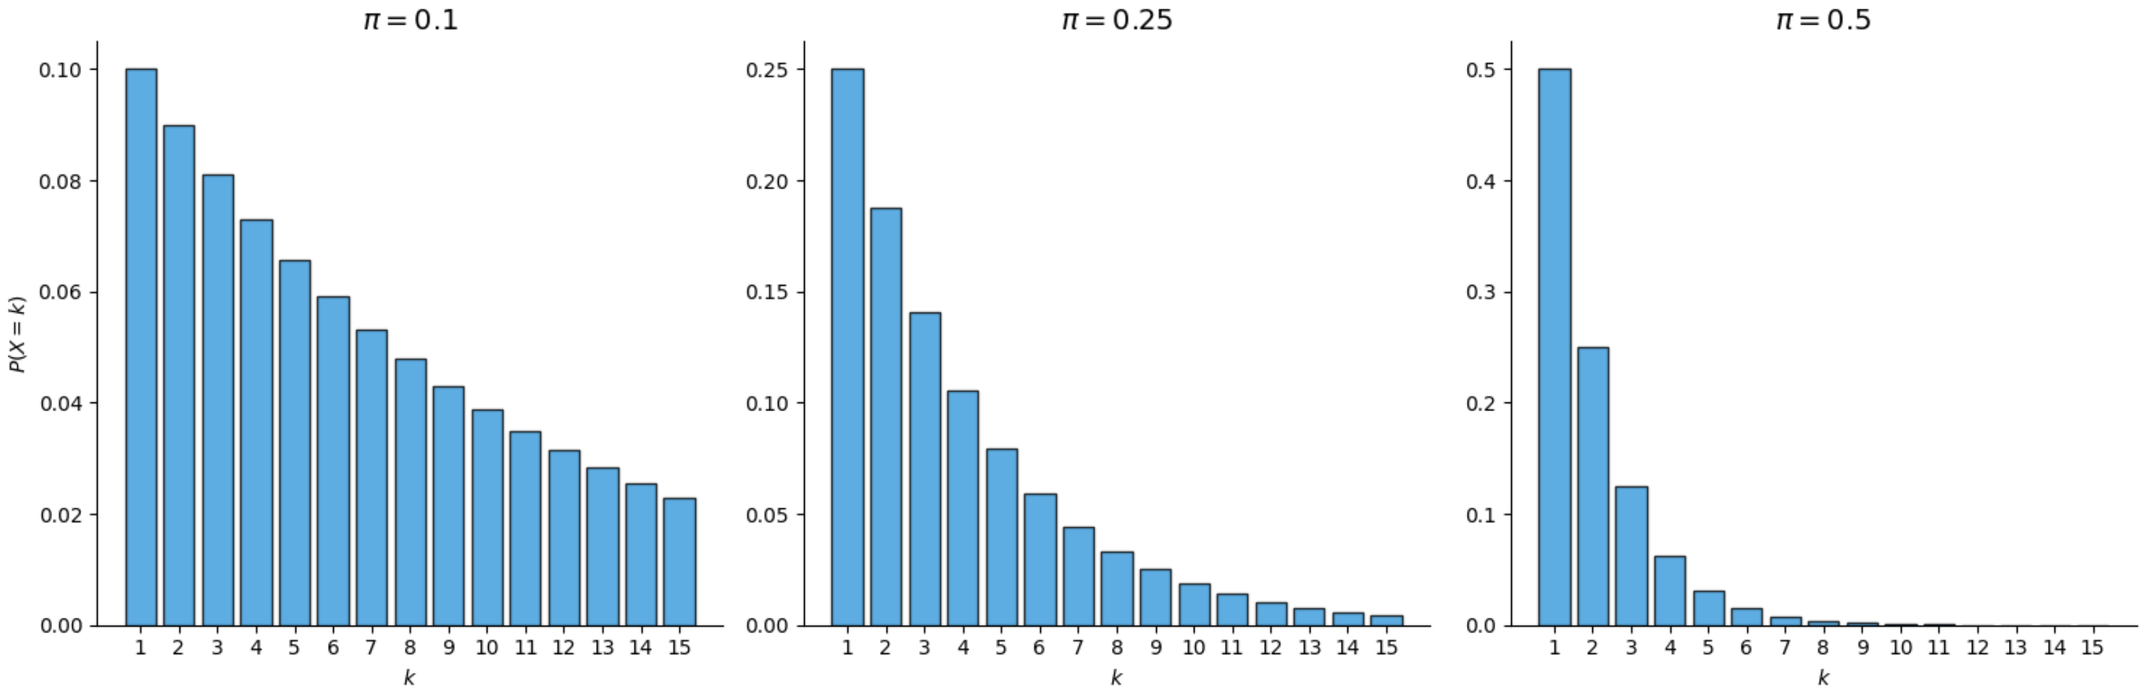


DSI Data Science Institute

Geometrische Verteilung

Ein Bernoulli-Experiment mit der Wahrscheinlichkeit $\pi = P(A)$ wird so lange wiederholt, bis das interessierende Ereignis A zum ersten Mal eintritt. X = „Anzahl der Versuche, bis A zum ersten Mal eintritt“. Die geometrische Verteilung ist im Grunde die „Wie lange muss ich noch warten?“-Verteilung.

Eine diskrete Zufallsvariable X heißt **geometrisch** verteilt mit Parameter π. Bezeichnung: $X \sim G(\pi)$.

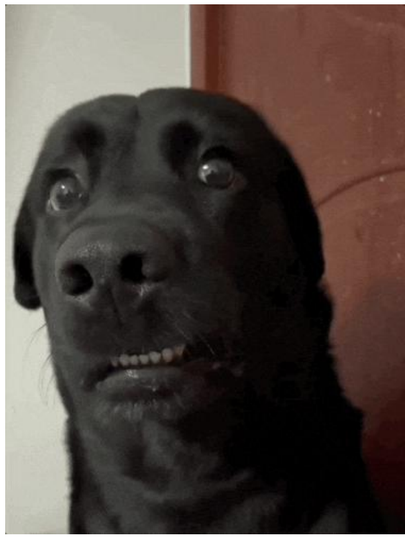


DSI Data Science Institute

Geometrische Verteilung - Beispiel

Stell dir vor, du bist beim Basketball-Training und übst Freiwürfe. Deine Trefferquote liegt bei 20%, also ist $p = 0{,}2$. Du wirfst so lange, bis du zum ersten Mal triffst. Dann hörst du auf.

Die Geometrische Verteilung beantwortet die Frage: Wie wahrscheinlich ist es, dass ich genau beim k-ten Versuch meinen ersten Treffer lande?



- $p = 0{,}20$: Die Wahrscheinlichkeit für einen Treffer (Erfolg).
- $1 - p = 0{,}80$: Die Wahrscheinlichkeit für einen Fehlwurf (Misserfolg).
- X: Die Zufallsvariable für die Anzahl der Versuche bis zum ersten Treffer.
- $k = 4$: Wir suchen die Wahrscheinlichkeit, dass der **4. Wurf** der erste Treffer ist.

Damit der 4. Wurf der erste Treffer ist, müssen die ersten 3 Würfe Fehlwürfe sein:

$$P(X = k) = (1 - p)^{k-1} \cdot p$$

Eingesetzt für $k = 4$:

$$P(X = 4) = 0{,}80^3 \cdot 0{,}20 = 0{,}512 \cdot 0{,}20 = 0{,}1024$$

Die Wahrscheinlichkeit, genau beim vierten Versuch das erste Mal zu treffen, liegt bei ca. 10,2%.

Geometrische Verteilung - Beispiel

Stell dir vor, du bist beim Basketball-Training und übst Freiwürfe. Deine Trefferquote liegt bei 20%, also ist $p = 0{,}2$. Du wirfst so lange, bis du zum ersten Mal triffst. Dann hörst du auf.

- $p = 0{,}20$: Die Wahrscheinlichkeit für einen Treffer (Erfolg).
- X: Die Zufallsvariable für die Anzahl der Versuche bis zum ersten Treffer.
- $k = 4$: Wir suchen die Wahrscheinlichkeit, dass der **4. Wurf** der erste Treffer ist.

Python:

```
from scipy.stats import geom
p = 0.20
k = 4

# Wahrscheinlichkeit für den ersten Treffer beim k-ten Versuch (PMF)
prob = geom.pmf(k, p) # Probability mass function
print(f"Wahrscheinlichkeit, dass der {k}. Wurf der erste Treffer ist: {prob:.4f}")
```

Statistische Kennzahlen - Erwartungswert

Der Erwartungswert $E(X)$ einer diskreten Zufallsvariable mit den Werten $x_1, x_2, \dots, x_k, \dots$ und der Wahrscheinlichkeitsverteilung $p_1, p_2, \dots, p_k, \dots$ ist

$$E(X) = x_1 \cdot p_1 + \cdots + x_\mathrm{k} \cdot p_\mathrm{k} + \cdots = \sum_{\mathrm{i} \geq 1}^{n} x_\mathrm{i} \cdot p_\mathrm{i}$$

Andere Bezeichnungen: μ_X, μ.

Beispiel:

Beim Werfen eines Würfels ist $E(X) = 1 \cdot \frac{1}{6} + 2 \cdot \frac{1}{6} + 3 \cdot \frac{1}{6} + 4 \cdot \frac{1}{6} + 5 \cdot \frac{1}{6} + 6 \cdot \frac{1}{6} = 3{,}5$.

Der Erwartungswert von 3,5 ist der langfristige Durchschnittswert aller Ergebnisse, dem sich dein tatsächlicher Mittelwert bei sehr vielen Würfen immer weiter annähert, obwohl die 3,5 selbst kein mögliches Würfelergebnis ist.

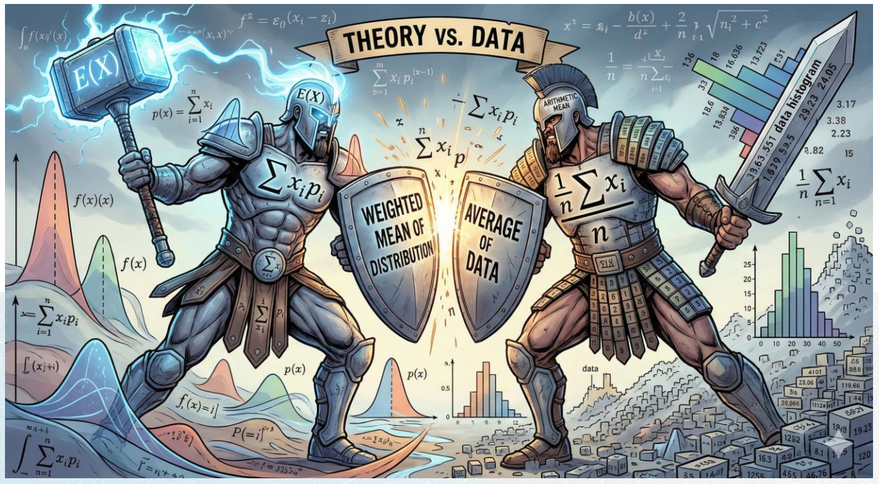
Erwartungswert vs. Arithmetisches Mittel

Der **Erwartungswert** ist im Grunde ein gewichtetes Mittel der möglichen Werte, wobei p_k als Gewichte dienen.

Obwohl er mathematisch fast wie ein normaler Durchschnitt (arithmetisches Mittel) aussieht, gibt es einen entscheidenden Unterschied in der Anwendung:

- Das **arithmetische Mittel** beschreibt die Lage von echten **Daten**, die du bereits gesammelt hast.
- Der **Erwartungswert** beschreibt dagegen die Lage der **theoretischen Verteilung**.

Du kannst den Erwartungswert bestimmen, ohne das Experiment überhaupt durchzuführen – du brauchst also gar keine realen Daten, um zu wissen, wo das Zentrum der Verteilung liegt.



DSI Data Science Institute

Erwartungswert – Beispiele

- **Gleichverteilung:**

$$E(X) = \frac{\text{Startwert} + \text{Endwert}}{2}$$

- **Geometrische Verteilung:**

$$E(X) = \frac{1}{\pi}$$

Varianz und Standardabweichung

Die **Varianz** einer diskreten Zufallsvariable ist:

$$Var(X) = E\big((X - \mu)^2\big)$$

Kurz gesagt: Varianz zeigt uns, wie weit deine Ergebnisse im Schnitt von der Mitte (dem Erwartungswert) weg sind, nur eben als „Abstand hoch zwei“. Also, das ist quasi der durchschnittliche "quadrierte Ausrutscher" von deinem X nach oben oder unten vom $E(X)$ weg.

Die **Standardabweichung** ist

$$\sigma = \sqrt{Var(X)}$$

Varianz und Standardabweichung - Beispiel

Verschiebungsregel

$$Var(X) = E(X^2) - (E(X))^2 = E(X^2) - \mu^2$$

Beispiel

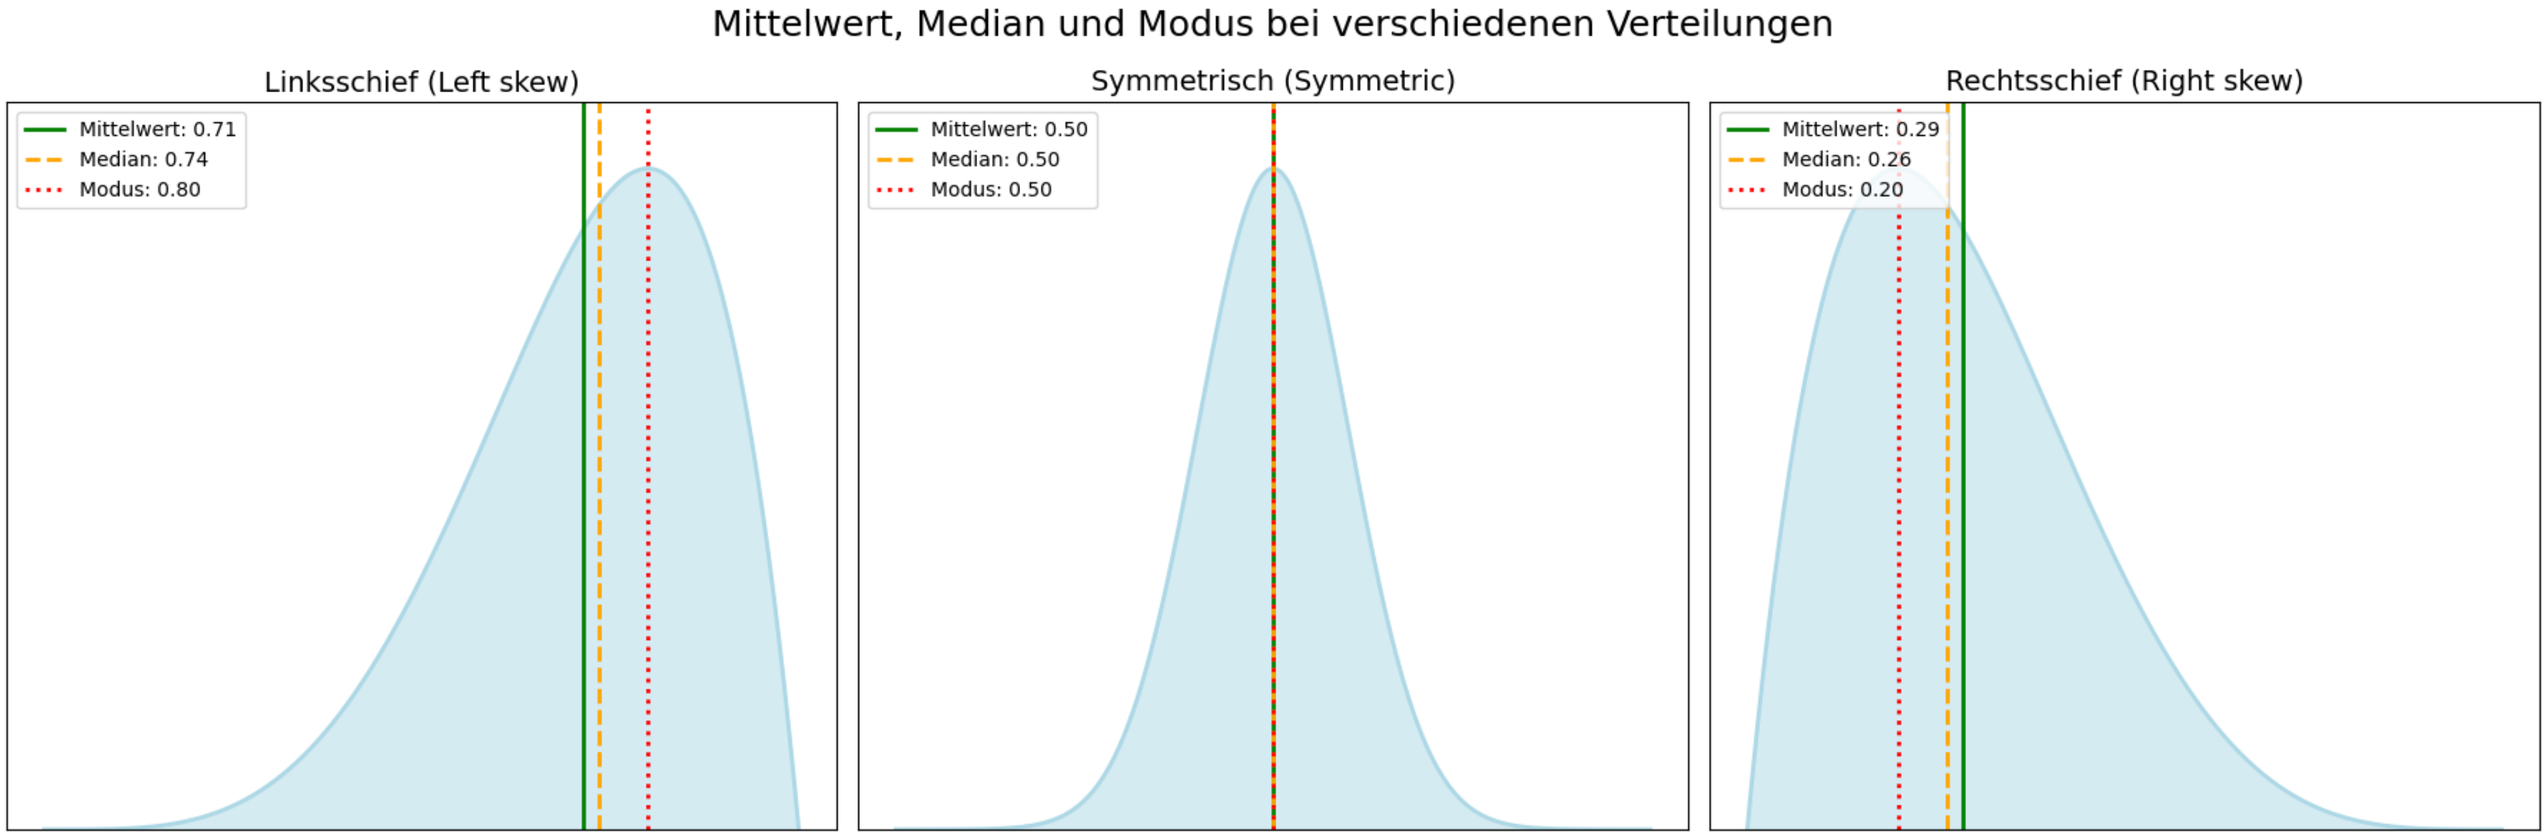
Beim einmaligen Würfeln gilt also

$$Var(X) = E(X^2) - \mu^2 = \frac{1}{6}(1^2+2^2+3^2+4^2+5^2+6^2) - 3{,}5^2 \approx 2{,}92$$

$$\sigma = \sqrt{Var(X)} \approx 1{,}71$$

DSI Data Science Institute

Verteilungskennzahlen - Schiefe (Skewness)



Binomialverteilung

Wir betrachten eine Bernoulli-Kette von n-mal wiederholten Bernoulli-Experimenten mit $\pi = P(A)$ für das interessierende Ereignis und der Folge $A_1, A_2, \ldots, A_n$ von **unabhängigen** Ereignissen.

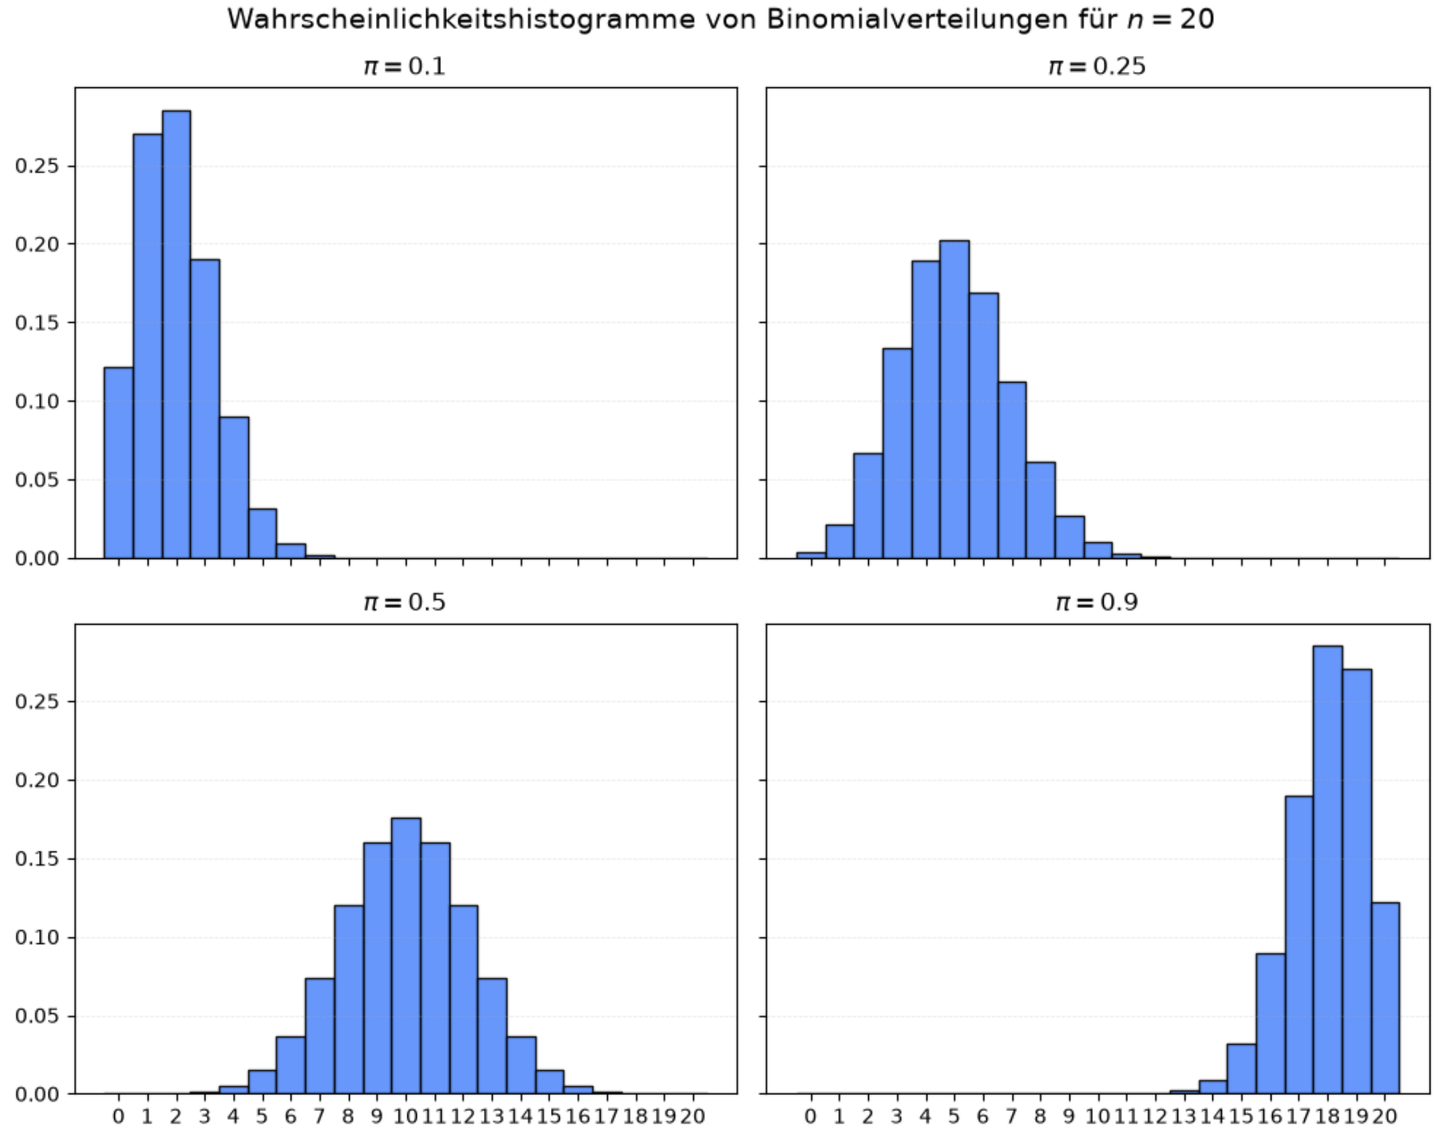
$$X = "Anzahl\ der\ Versuche, bei\ denen\ A\ eintritt".$$

Beispiel:

Es wird wiederholt gewürfelt, wobei gezählt wird, wie oft eine „Sechs“ erscheint.

Die Verteilung heißt **Binomialverteilung** oder kurz $B(n, \pi)$ −Verteilung. Sie ergibt sich, wenn aus n unabhängigen Wiederholungen eines Bernoulli-Experiments mit konstanter Wahrscheinlichkeit π die Summe der Treffer gebildet wird.

Binomialverteilung



DSI Data Science Institute

Binomialverteilung - Beispiel

Wir untersuchen eine Produktion, bei der 95 % der Teile top sind. Wir interessieren uns aber für die Kaputten.

- $n = 10$: Die Anzahl der Versuche (wir kaufen 10 Teile).
- π: Die Wahrscheinlichkeit für einen „Erfolg“ (Teil ist kaputt, $0{,}05$).
- X: Die Zufallsvariable – sie zählt, wie viele Teile kaputt sind.
- k: Die genaue Anzahl der kaputten Teile, die wir suchen ($k = 1$ und $k = 2$)

```
from scipy.stats import binom
n = 10
p = 0.05

k = 2

prob_exact = binom.pmf(k, n, p)
print(f"Wahrscheinlichkeit für genau {k} kaputte Teile: {prob_exact:.4f}")

# Kumulierte Wahrscheinlichkeit: "Höchstens k kaputte Teile„ - P(X <= 2) -> (P(0) + P(1) + P(2))
prob_upto = binom.cdf(k, n, p) # Cumulative distribution function
print(f"Wahrscheinlichkeit für höchstens {k} kaputte Teile: {prob_upto:.4f}")
```

Poisson-Verteilung

Die **geometrische Verteilung** zählt, wie lange man warten muss, bis ein Ereignis A zum ersten Mal eintritt. Der Wertebereich ist die Menge $\mathbb{N}$ der natürlichen Zahlen und nicht nach oben begrenzt (nicht wie Binomialverteilung, begrenzt durch n).

Die **Poisson-Verteilung** eignet sich ebenfalls zur Modellierung von Zählvorgängen. Dabei werden bestimmte Ereignisse gezählt, die innerhalb eines festen, vorgegebenen Zeitintervalls eintreten können. Die mögliche Anzahl der Ereignisse ist nicht nach oben begrenzt.

Beispiel:

- Die Anzahl von Schadensmeldungen bei einer Versicherung innerhalb eines Jahres.
- Die Anzahl der Grippefälle in einem Monat.

Poisson-Verteilung

Eine Zufallsvariable heißt **Poisson-verteilt** mit den Parametern $\lambda > 0$, kurz $X \sim Po(\lambda)$.
Für größeres λ, etwa ab $\lambda \geq 10$, wird die Verteilung annähernd symmetrisch.

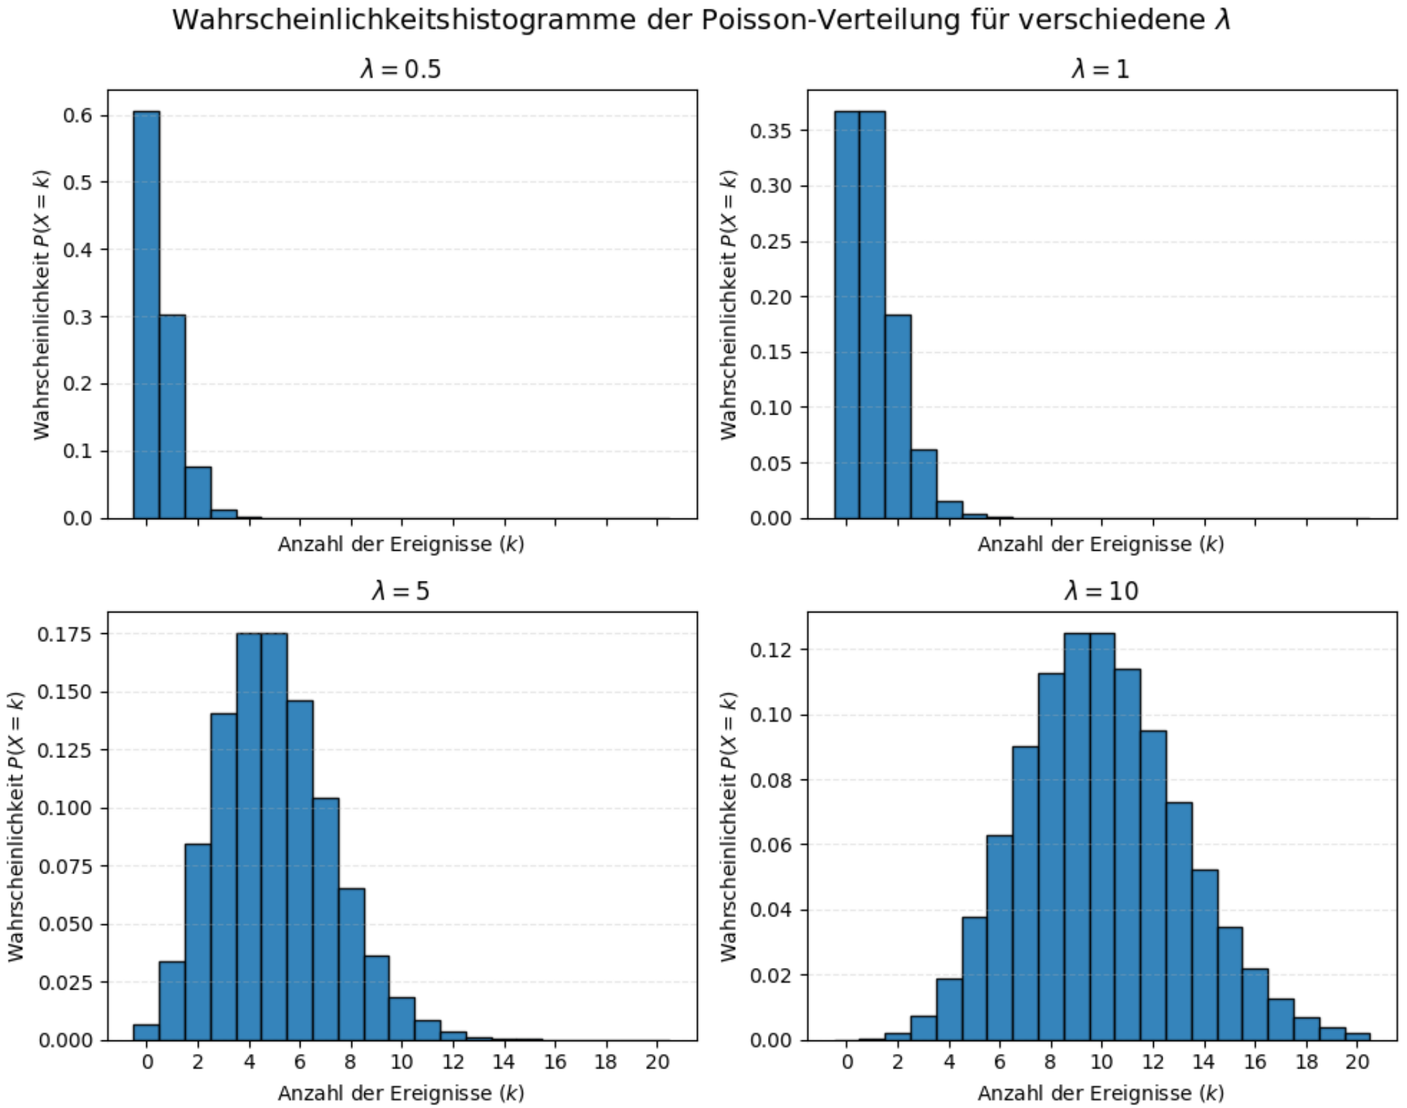
$$E(X) = \lambda$$
$$Var(X) = \lambda$$

Lambda (λ) ist deine durchschnittliche Trefferquote. Es beschreibt die **Rate**, also wie oft ein Ereignis im Durchschnitt in einem bestimmten Zeitraum (oder Raum) auftritt.

Wenn du weißt, dass in deiner Fabrik im Schnitt **2** Maschinen pro Monat ausfallen, dann ist $\lambda = 2$.

Im Gegensatz zur Binomialverteilung brauchst du bei Poisson **kein festes n** (Anzahl der Versuche) oder π (Einzelwahrscheinlichkeit). Du musst nur wissen, wie oft es im Schnitt "knallt".

Poisson-Verteilung



Data Science Institute

Poisson-Verteilung - Beispiele

Wenn an einer Bushaltestelle im Schnitt alle 10 Minuten **3** Leute ankommen, ist dein $\lambda = 3$ für das Zeitintervall von 10 Minuten. Wir wollen wissen, wie wahrscheinlich es ist, dass genau **5 Leute** ($k = 5$) auftauchen.

```
from scipy.stats import poisson

# Parameter mu entspricht dem Lambda (Schnitt)
lam = 3
k = 5

prob_exact = poisson.pmf(k, lam)


# Kumulierte Wahrscheinlichkeit (CDF): "Höchstens 5 Leute"
# P(X <= 5)
prob_upto = poisson.cdf(k, lam)
print(f"Wahrscheinlichkeit für höchstens {k} Personen: {prob_upto:.4f}")
```

Poisson-Verteilung - Beispiele

Man nutzt die Poisson-Verteilung immer dann, wenn Ereignisse **unabhängig** voneinander in einem festen Bereich (Zeit oder Raum) „auftauchen". Ein gutes Beispiel ist das: **Schneeflocken auf einer Gehwegkachel**. Wenn es gleichmäßig schneit, landen im Durchschnitt vielleicht 50 Flocken auf jeder Kachel. Aber auf einer Kachel landen mal 42, auf der anderen 58 – das ist reiner Zufall, folgt aber genau diesem Muster.