Statistik

Stetige Zufallsvariablen und Verteilungen

DSI Data Science Institute

Inhaltsverzeichnis

1. Grundbegriffe
2. Stetige Gleichverteilung
3. Exponentialverteilung
4. Normalverteilung
5. Chi-Quadrat-Verteilung
6. t-Verteilung
7. F-Verteilung

Lernziele

- Stetige Zufallsvariablen, Dichtefunktionen und Verteilungsfunktionen beschreiben sowie Wahrscheinlichkeiten als Flächen unter einer Dichtefunktion interpretieren.

- Eigenschaften wichtiger stetiger Verteilungen vergleichen sowie die Bedeutung für statistische Schätz- und Testverfahren einordnen.

Grundbegriffe - Wahrscheinlichkeitsdichte

Eine Variable oder ein Merkmal X heißt **stetig**, falls zu zwei Werten $a < b$ auch jeder Zwischenwert im Intervall $[a, b]$ möglich ist ($\{a \leq X \leq b\}$).

Die Funktion $f(x)$ heißt **(Wahrscheinlichkeits-) Dichte** von X, wenn die Wahrscheinlichkeit $P(a \leq X \leq b)$ gleich der Fläche zwischen dem Intervall $[a, b]$ ist.

Normierungseigenschaft: die Gesamtfläche zwischen x-Achse und der Dichte $f(x)$ ist gleich 1.

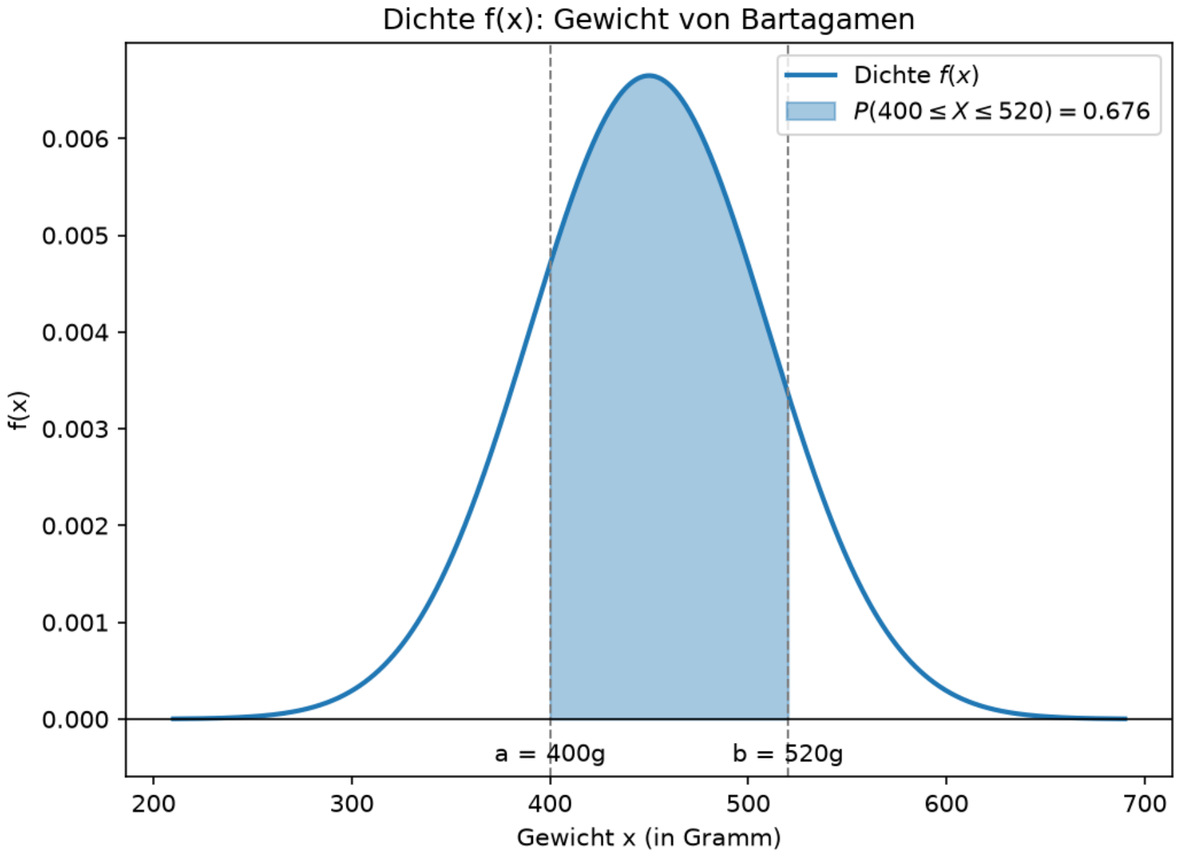
Grundbegriffe - Verteilungsfunktion

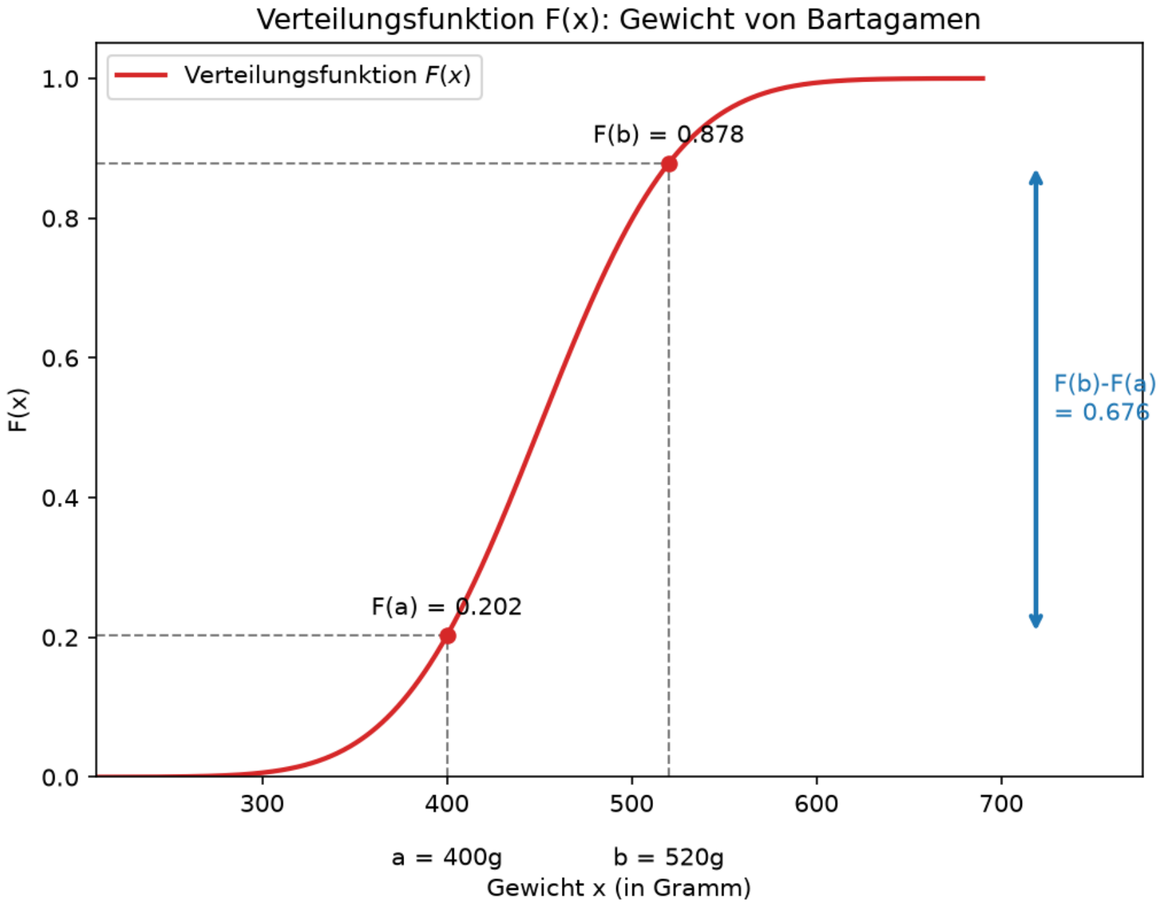
Die **Verteilungsfunktion** einer stetigen Zufallsvariable ist die Gesamtfläche zwischen dem Teil der x-Achse links vom Wert x und der darüberliegenden Dichte.

Diese Beziehung ist das stetige Analogon zur Beziehung im diskreten Fall.

- $\boldsymbol{P(a \leq X \leq b) = F(b) - F(a)}$
- $P(X \geq a) = 1 - F(a)$

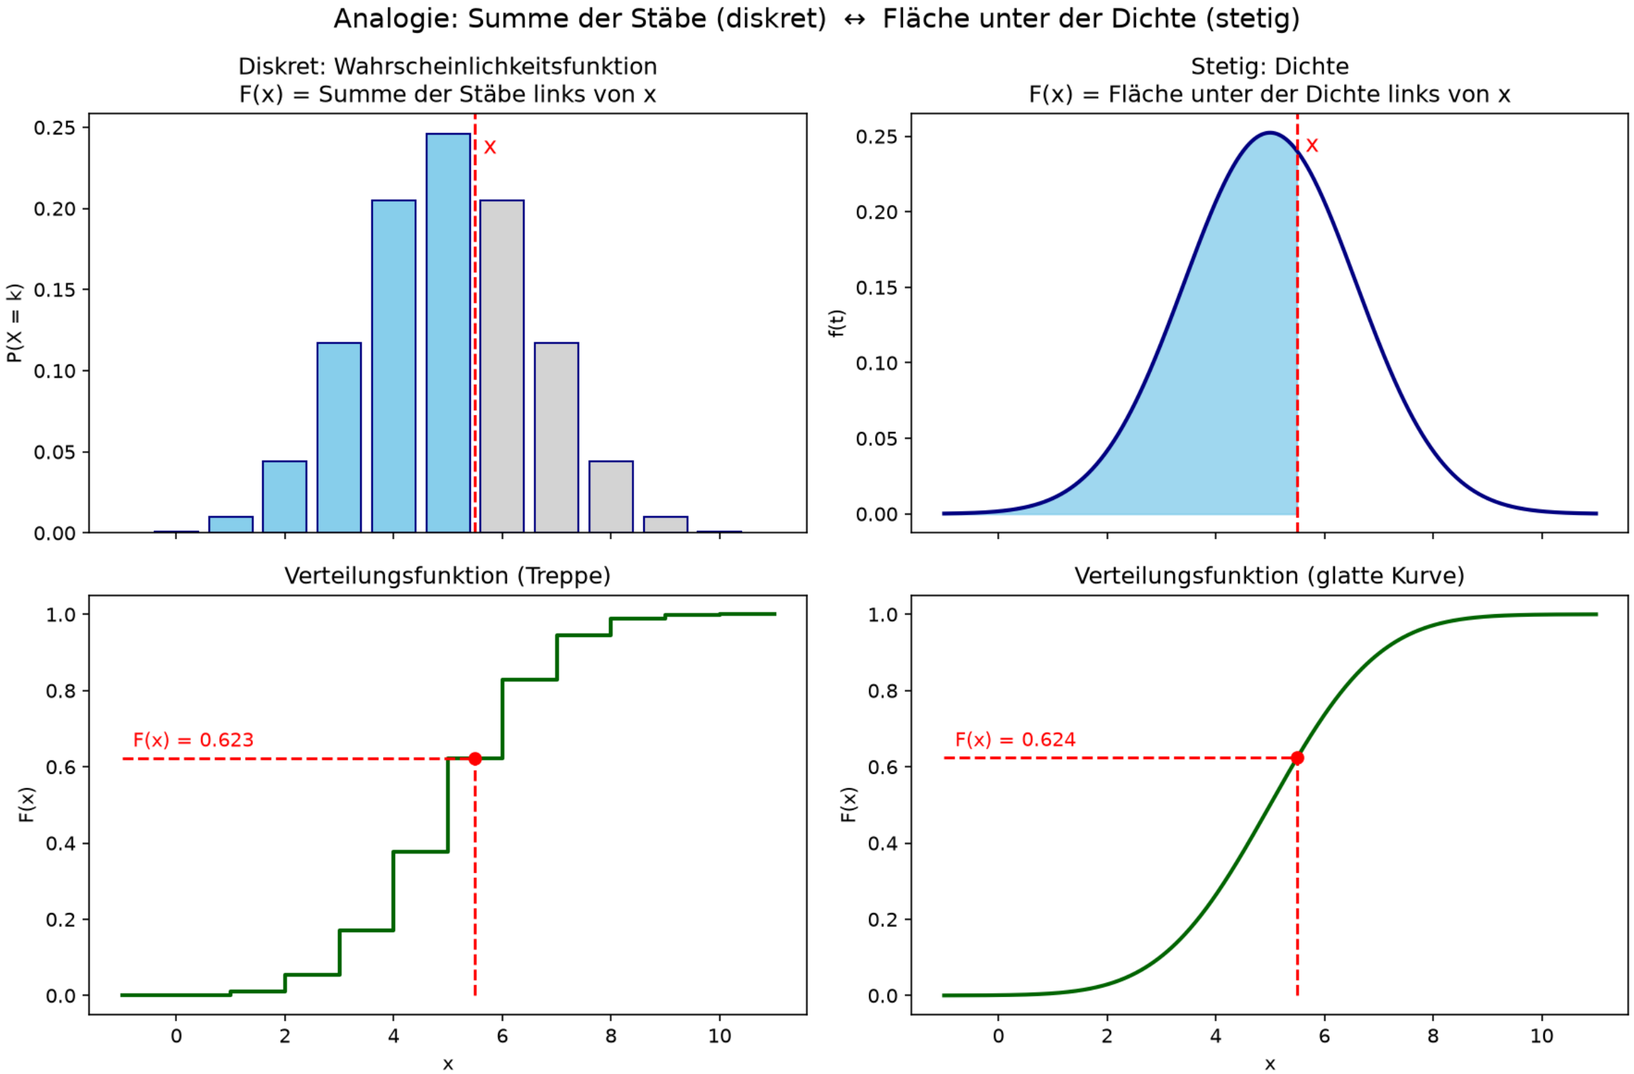
Grundbegriffe - Verteilungsfunktion





Data Science Institute

Grundbegriffe - Verteilungsfunktion

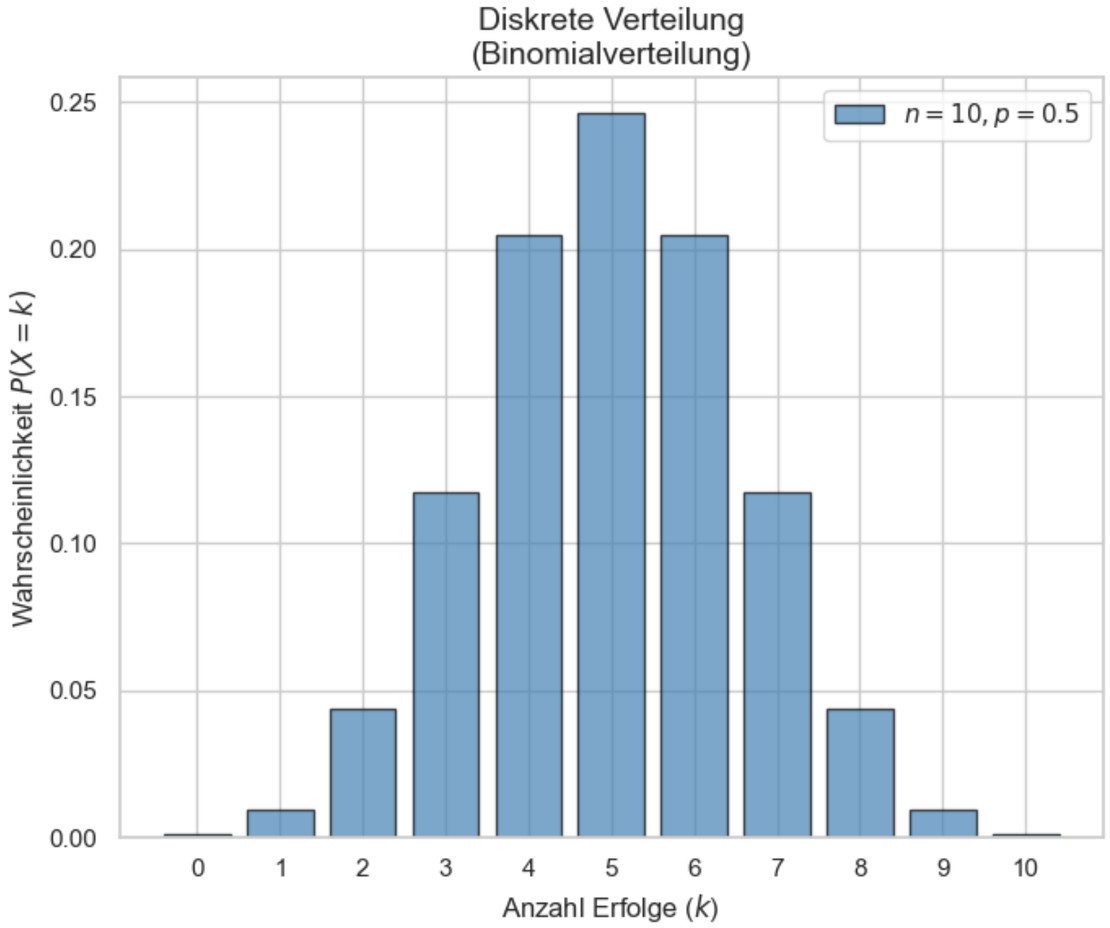


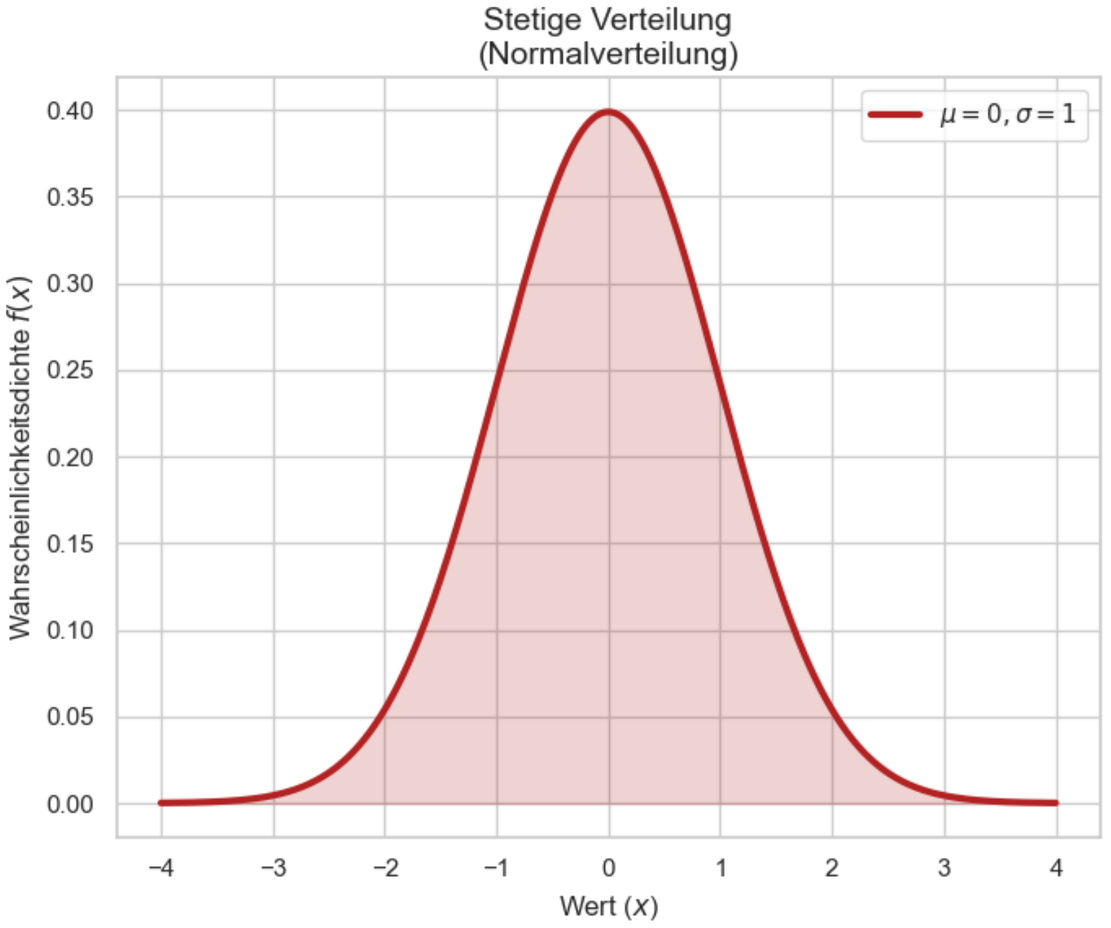
DSI Data Science Institute

Grundbegriffe - Wahrscheinlichkeitsdichte

- Die Dichte $f(x)$ besitzt einige Analogien zur Wahrscheinlichkeitsfunktion einer diskreten Zufallsvariable.
- Ein wesentlicher Unterschied ist jedoch, dass die Werte $f(x)$ einer stetigen Dichte **keine** Wahrscheinlichkeiten, denn ein einzelner Punkt hat keine Breite und damit die Fläche 0, also gilt $P(X = x) = 0$
- Wahrscheinlichkeiten ergeben sich erst aus der Fläche über einem Intervall.

Grundbegriffe - Wahrscheinlichkeitsdichte





DSI Data Science Institute

Stetige Gleichverteilung

Eine stetige Zufallsvariable heißt **gleichverteilt** auf dem Intervall [*a, b*], wenn sie eine Dichte

$$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq \mathrm{x} \leq b \\ 0, & sonst \end{cases}$$

besitzt.

Die **Verteilungsfunktion**:

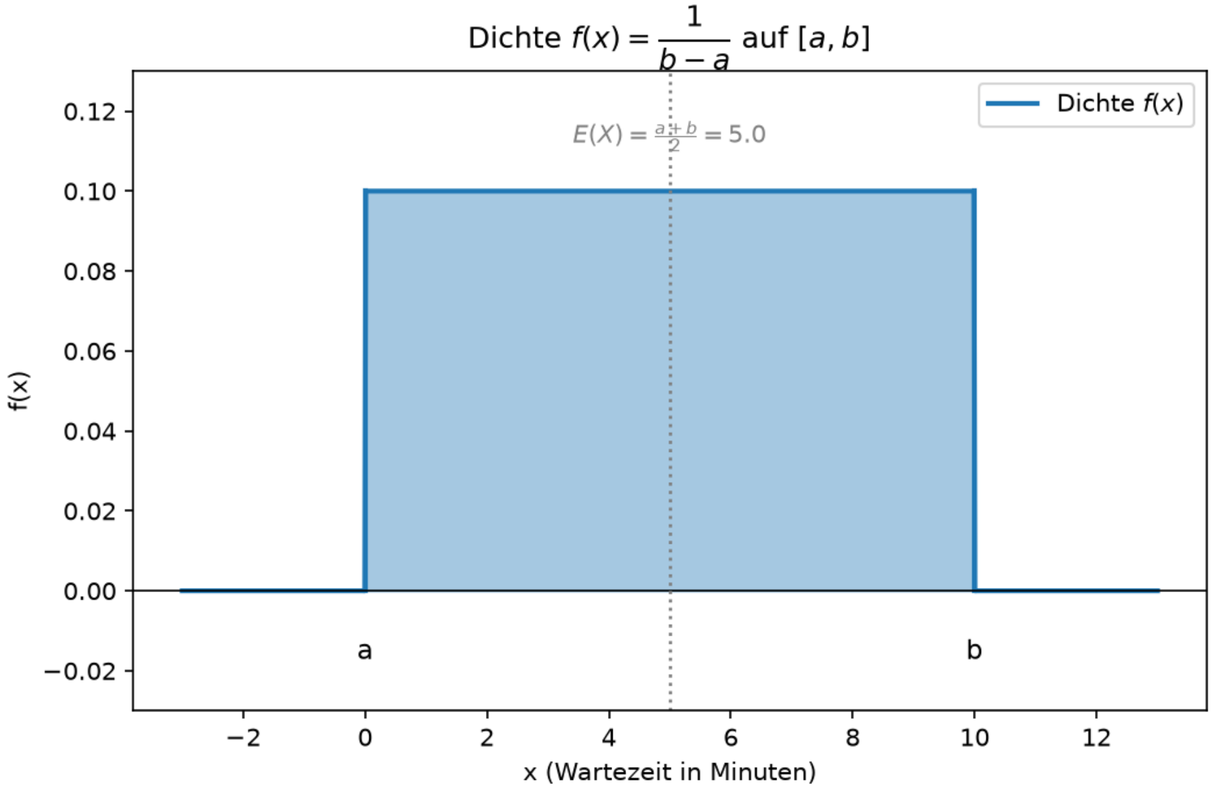
$$F(x) = \begin{cases} 0, & \mathrm{x} < \mathrm{a} \\ \frac{\mathrm{x}-\mathrm{a}}{\mathrm{b}-\mathrm{a}}, & a \leq X \leq b \\ 1, & \mathrm{x} > \mathrm{b} \end{cases}$$

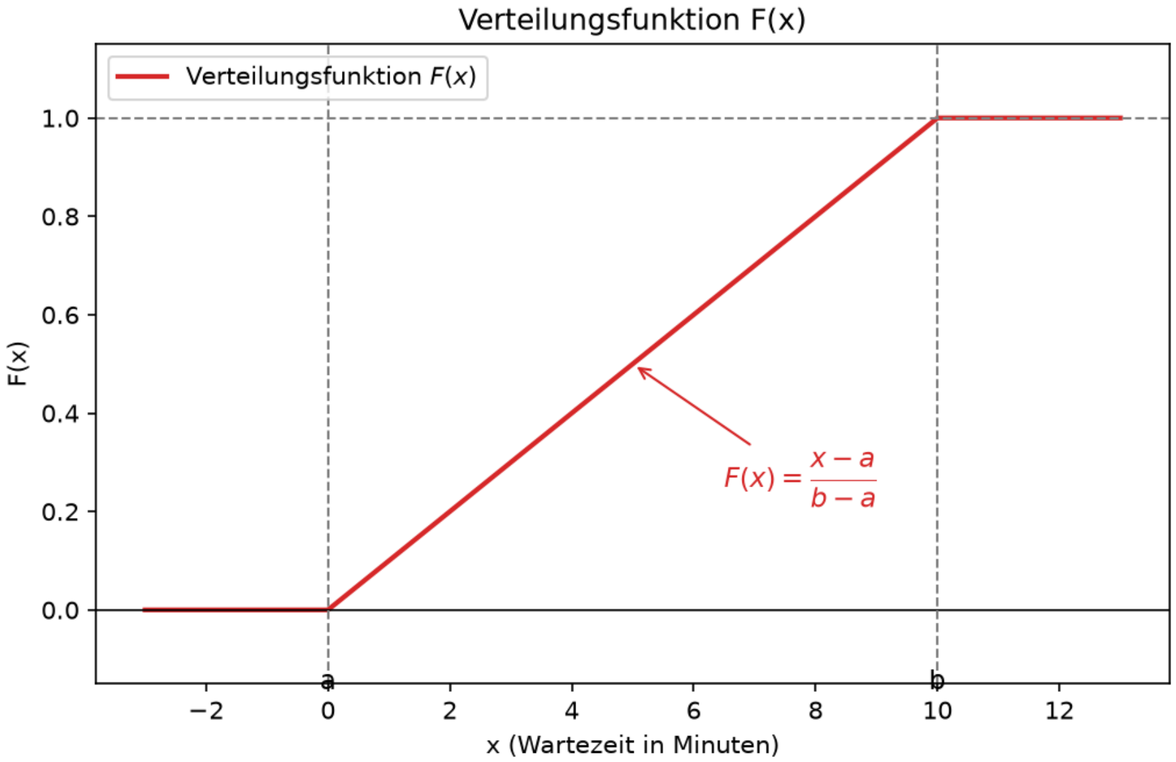
$$E(X) = \frac{\mathrm{a}+\mathrm{b}}{2}$$

$$Var(X) = \frac{(\mathrm{b}-\mathrm{a})^2}{12}$$

Stetige Gleichverteilung

Gleichverteilung auf $[0, 10]$ — Beispiel: Wartezeit auf den Bus $(E(X) = 5.0,\ Var(X) = 8.33)$





Data Science Institute

Stetige Gleichverteilung - Beispiel

Das Warten auf die Pizza

Stell dir vor, du hast Pizza bestellt. Die App sagt: „Deine Pizza kommt in 30 bis 50 Minuten“. Du hast keine Ahnung, wann genau der Bote klingelt, aber innerhalb dieses Zeitfensters ist jeder Augenblick **gleich wahrscheinlich.** $X \sim U(a, b)$.

Höhe der Dichte:

$$f(x) = \frac{1}{b-a} = \frac{1}{50-30} = 0{,}05$$

Wie groß ist die Chance, dass die Pizza in den nächsten 5 Minuten kommt (also zwischen Minute 30 und 35)?

Stetige Gleichverteilung - Beispiel

$$P(30 \leq X \leq 35) = F(35) - F(30) = \frac{35-30}{50-30} - \frac{30-30}{50-30} = 0{,}25 \; - \; 0$$

Es gibt eine 25% Chance, dass der Bote in diesem 5-Minuten-Fenster klingelt.

Python:

```
from scipy.stats import uniform

a = 30  # Untergrenze
b = 50  # Obergrenze
breite = b - a  # Die Breite des Intervalls (scale)


# Die Verteilung definieren - loc ist der Startpunkt, scale ist die Breite
pizza_dist = uniform(loc=a, scale=breite)

wahrscheinlichkeit = pizza_dist.cdf(35) - pizza_dist.cdf(30)

print(f"Chance, dass die Pizza zwischen Minute 30 und 35 kommt: {wahrscheinlichkeit:.2%}")
```

Exponentialverteilung

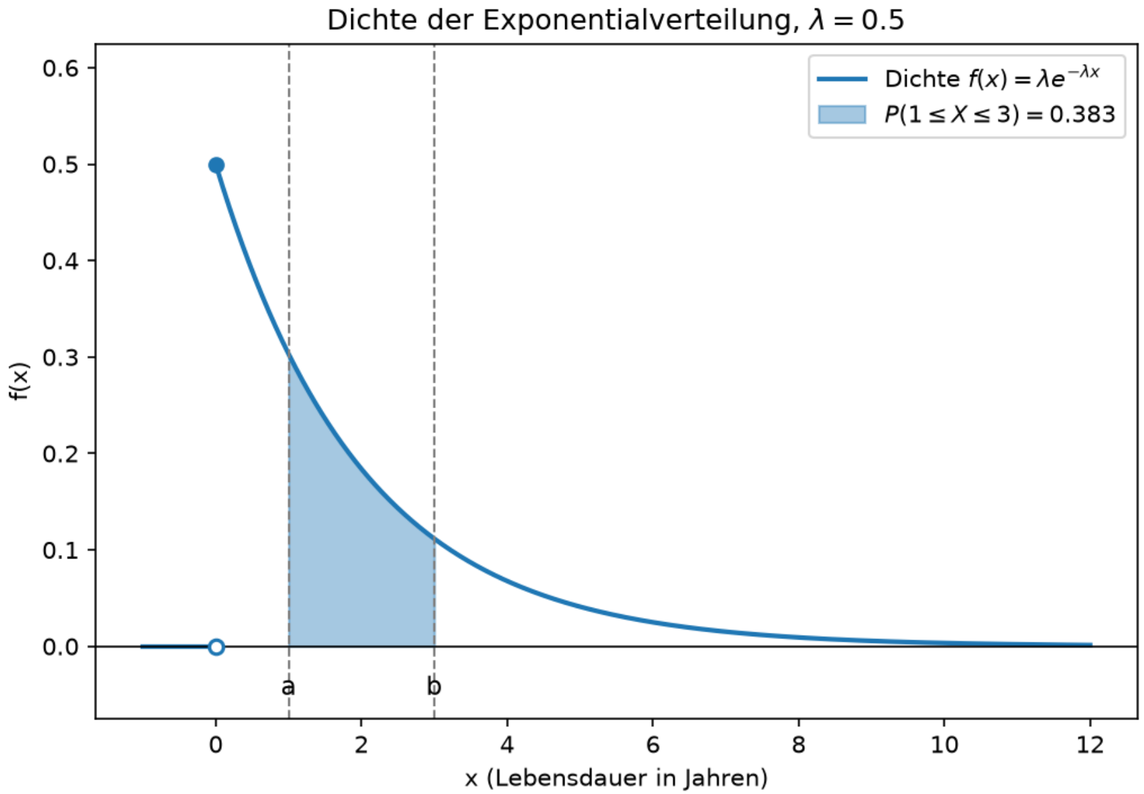
Ein Ereignis A tritt zu zufälligen Zeitpunkten mit einer konstanten Rate λ ein (z. B. Anrufe pro Stunde). X = „Wartezeit, bis A zum ersten Mal eintritt“. Die **Exponentialverteilung** ist im Grunde die stetige „Wie lange muss ich noch warten?“-Verteilung und damit das stetige Analogon zur **geometrischen** Verteilung: Statt der Anzahl der Versuche wird die Zeit gemessen.

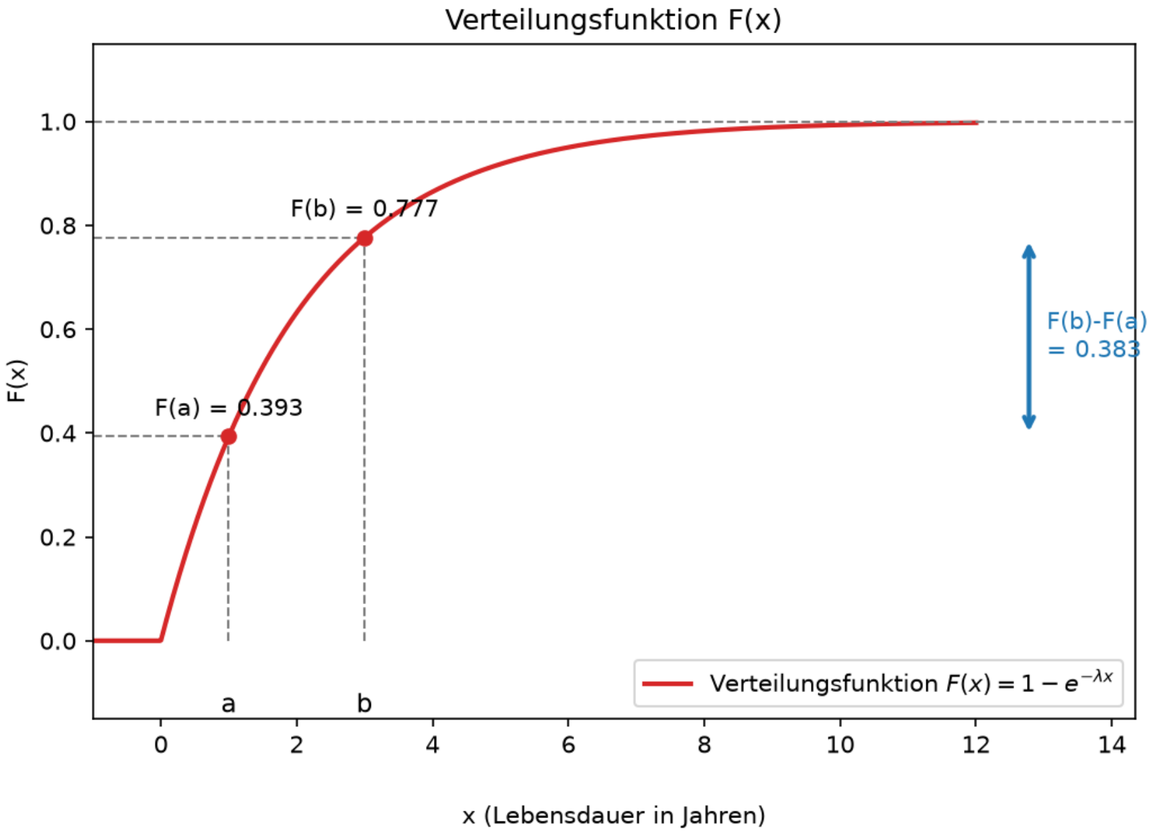
Eine stetige Zufallsvariable X heißt exponentialverteilt mit Parameter $\lambda > 0$. Bezeichnung: $X \sim \text{Exp}(\lambda)$.

- $E(X) = \frac{1}{\lambda}$
- $Var(X) = \frac{1}{\lambda^2}$

Exponentialverteilung

Exponentialverteilung $Ex(\lambda = 0.5)$ — Beispiel: Lebensdauer einer Glühbirne $(E(X) = 2.0,\ Var(X) = 4.00)$





Data Science Institute

Exponentialverteilung - Beispiel

Die Exponentialverteilung beschreibt oft die **Zeitdauer zwischen zwei Ereignissen**, die mit einer konstanten Rate λ eintreten.

Angenommen, bei einem IT-Support gehen im Durchschnitt **4 Anfragen pro Stunde** ein. Die Zeit X (in Stunden) bis zur nächsten Anfrage ist dann exponentialverteilt mit $\lambda = 4$.

$$E(X) = \frac{1}{\lambda} = \frac{1}{4}$$

Im Durchschnitt wartest du also 15 Minuten auf die nächste Anfrage.

Wie groß ist die Wahrscheinlichkeit, dass die nächste Anfrage innerhalb der nächsten 10 Minuten reinkommt?

Exponentialverteilung - Beispiel

Python:

```
from scipy.stats import expon

# Parameter festlegen
lam = 4                 # Anfragen pro Stunde
scale = 1 / lam         # Durchschnittliche Wartezeit (0.25 Stunden)

x = 1 / 6


# Wahrscheinlichkeit berechnen (CDF) - P(X <= 10 Min) = F(1/6)
prob = expon.cdf(x, scale=scale)

print(f"Wahrscheinlichkeit für eine Anfrage innerhalb von
{x*60:.0f}Min: {prob:.4f}")
```

Exponentialverteilung Exponential vs. Geometrisch vs. Poisson

Der „diskrete Bruder“ der Exponentialverteilung ist die **Geometrische Verteilung**.

Die Exponentialverteilung misst die **Zeit** bis zum ersten Ereignis (kontinuierlich). Die Geometrische Verteilung misst die **Anzahl der Versuche** bis zum ersten Erfolg (diskret).

Und was ist mit Poisson?

- **Poisson** beantwortet die Frage: „**Wie viele** Ereignisse passieren in einer festen Zeit?“ (z. B. 5 Mails pro Stunde).
- **Exponential** beantwortet die Frage: „**Wie viel Zeit** vergeht zwischen diesen Ereignissen?“ (z. B. im Schnitt 12 Minuten).

Normalverteilung



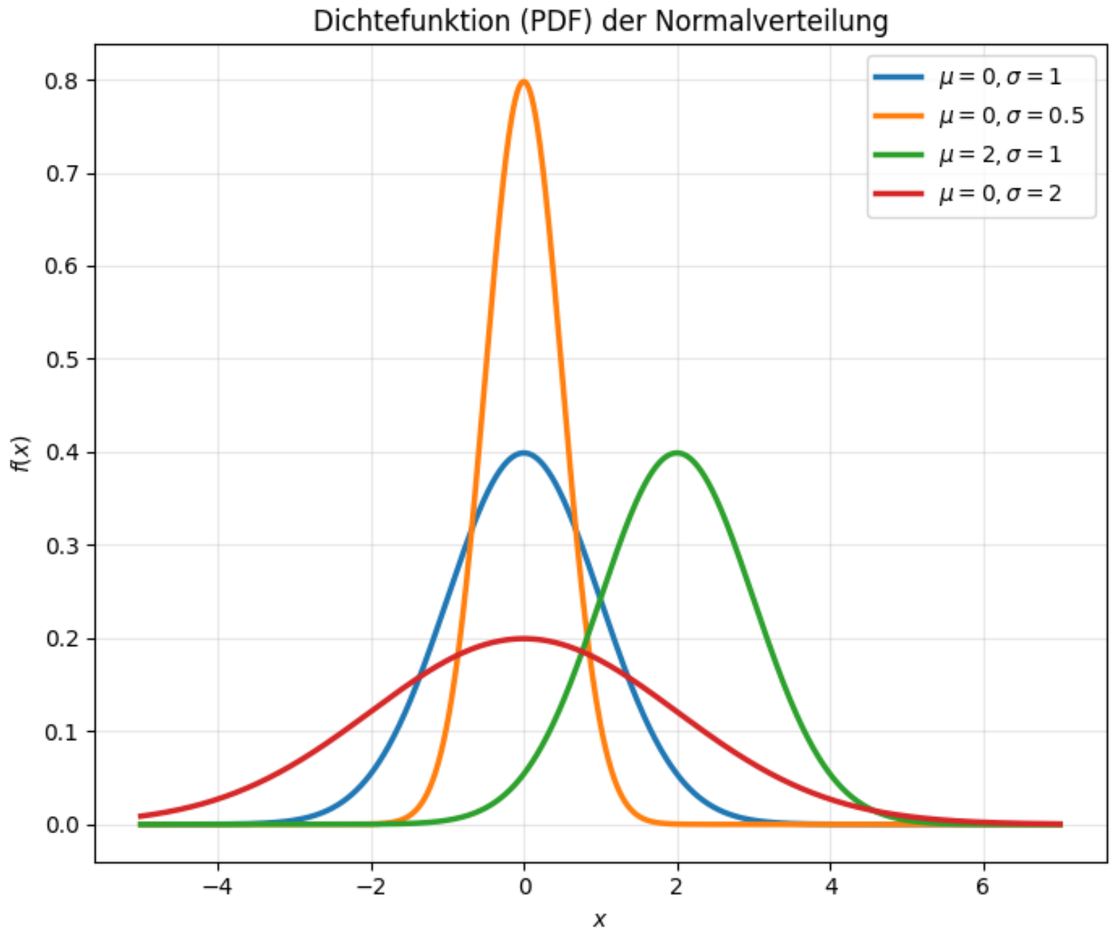
Eine Zufallsvariable X heißt **normalverteilt** mit Parametern μ und $\sigma^2 > 0$, kurz $X \sim N(\mu, \sigma^2)$.

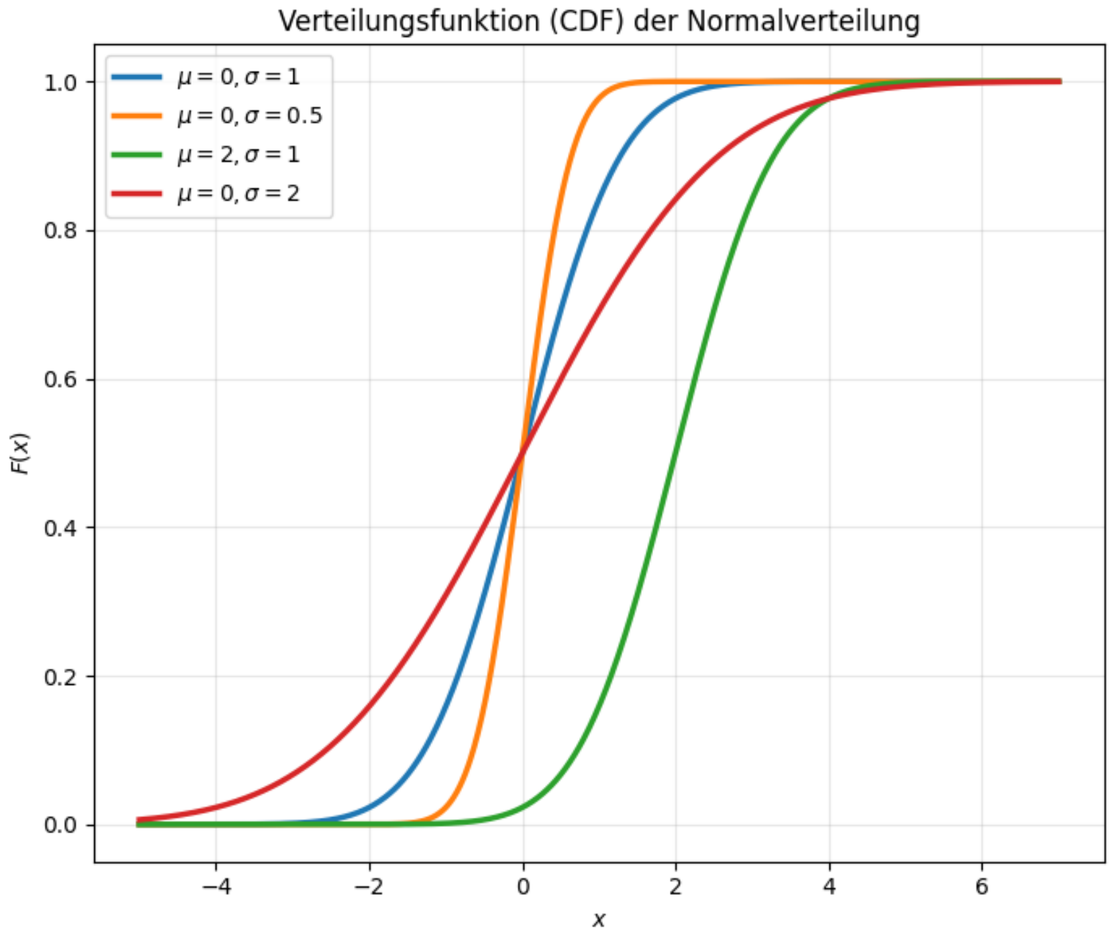
Es gilt $E(X) = \mu$ und $Var(X) = \sigma^2$.

Die Normalverteilung wird auch als **Gauß-Verteilung** und die Dichtekurve als Gauß-Kurve bezeichnet.

Speziell für $\mu = 0, \sigma^2 = 1$ erhält man die **Standardnormalverteilung** $N(0,1)$.

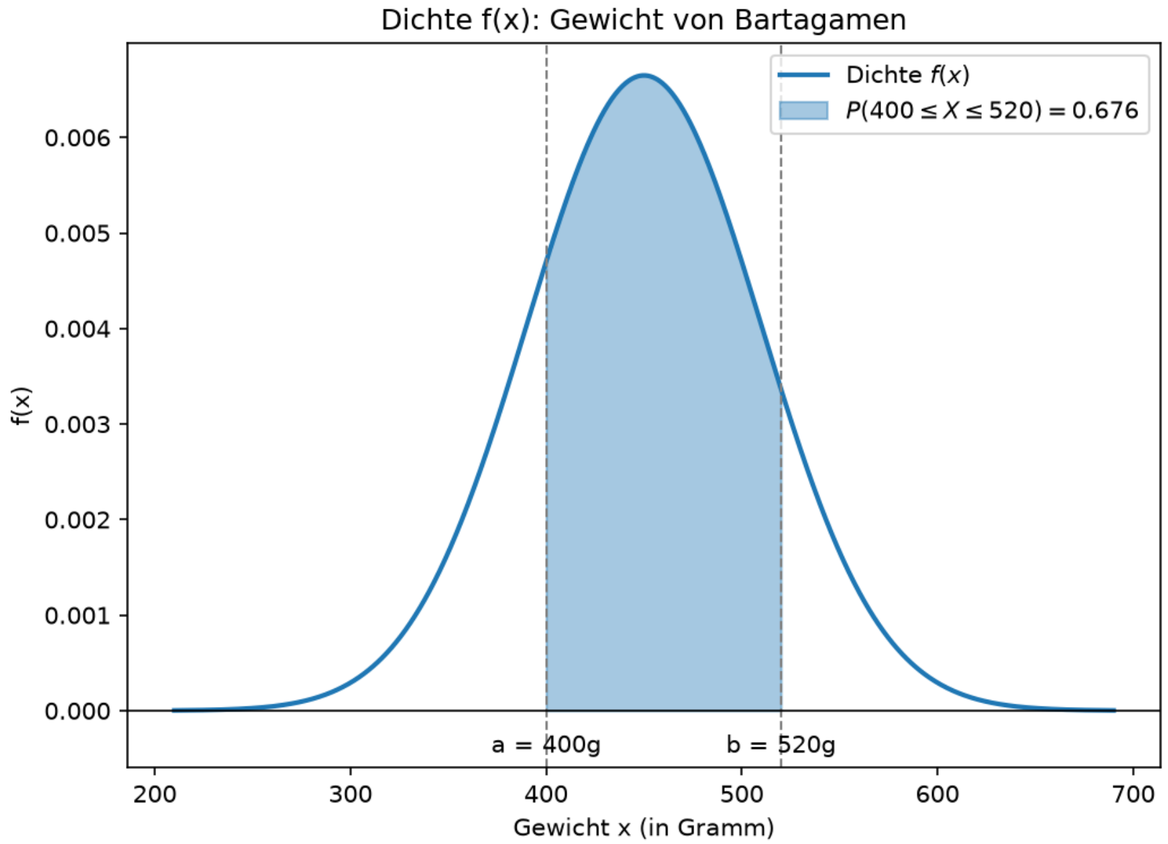
Normalverteilung

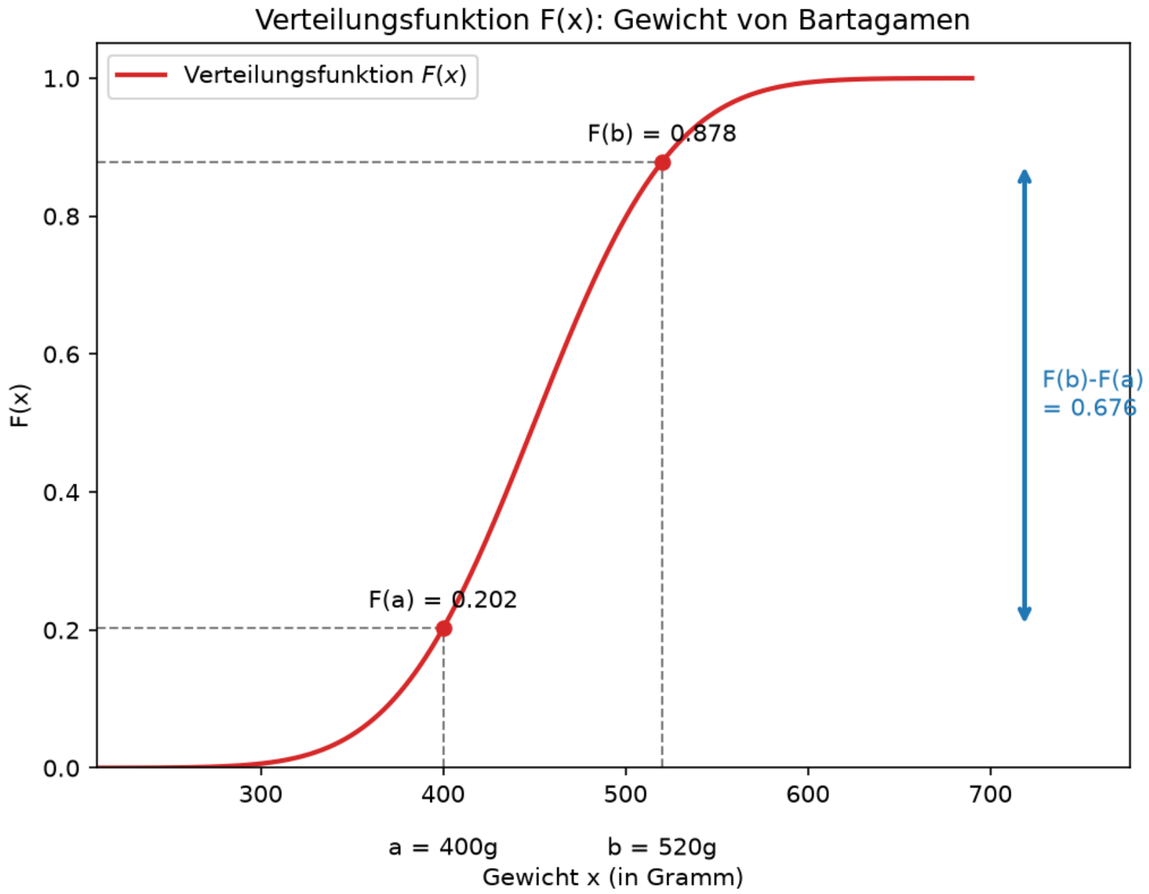




DSI Data Science Institute

Normalverteilung





Data Science Institute

Normalverteilung



Die **Normalverteilung** (auch **Gauß-Verteilung** genannt) ist die **bekannteste** und wichtigste Verteilung in der Statistik. Viele andere Verteilungen lassen sich durch die Normalverteilung gut approximieren, besonders wenn die Stichprobenanzahl groß wird. Ein wesentliches Merkmal ist ihre Symmetrie.

Zusätzlich lässt sich beobachten, dass unzählige Naturphänomene dieser „Glockenkurve“ folgen:

- **Körpergröße und Gewicht:** Wenn man die Größe aller erwachsenen Männer oder Frauen einer Population misst, häufen sich die Werte um den Mittelwert μ, während extrem kleine oder extrem große Personen immer seltener werde.
- **Merkmale in der Botanik:** Die Länge der Blätter an einem Baum, das Gewicht von Äpfeln einer Ernte oder die Anzahl der Erbsen in einer Schote folgen oft fast perfekt der Normalverteilung.
- **Messfehler in der Physik:** Wenn du denselben Gegenstand 100-mal mit einem präzisen Gerät misst, wirst du leichte Schwankungen feststellen. Diese zufälligen Messfehler streuen symmetrisch um den „wahren“ Wert herum.

Normalverteilung - Problem



- In der Statistik gibt es ein Problem: Die **Verteilungsfunktion** $F(x)$ der Normalverteilung lässt sich **nicht analytisch berechnen**. Das bedeutet, es gibt keine einfache Formel, in die man eine Zahl einsetzt, um direkt die Fläche unter der Glockenkurve zu erhalten.
- Da wir die Fläche aber brauchen, um Wahrscheinlichkeiten zu bestimmen, müssen wir das Integral eigentlich jedes Mal numerisch (also durch Näherung) lösen.
- Hinzu kommt eine zweite Hürde: Da es **unendlich viele Kombinationen** von Mittelwerten (μ) und Standardabweichungen (σ) gibt, existieren theoretisch unendlich viele Normalverteilungen.

Die Lösung: Die Standardisierung

Um diesem Chaos zu entkommen, nutzen wir die **Standardisierung**. Wir wandeln jede beliebige Normalverteilung $X \sim N(\mu, \sigma^2)$, mit einer einfachen Formel in die **Standardnormalverteilung** $Z \sim N(0,1)$, um:

$$Z = \frac{X - \mu}{\sigma}$$

Data Science Institute

Verteilungstabelle



Bsp.: $\mathrm{P}\left[Z \leq 1.96\right] = 0.975$

z	.00	.01	.02	.03	.04	.05	.06	.07	.08	.09
.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.2	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015
1.3	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1.4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279	0.9292	0.9306	0.9319
1.5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418	0.9429	0.9441
1.6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525	0.9535	0.9545
1.7	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616	0.9625	0.9633
1.8	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693	0.9699	0.9706
1.9	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756	0.9761	0.9767
2.0	0.9772	0.9778	0.9783	0.9788	0.9793	0.9798	0.9803	0.9808	0.9812	0.9817
2.1	0.9821	0.9826	0.9830	0.9834	0.9838	0.9842	0.9846	0.9850	0.9854	0.9857
2.2	0.9861	0.9864	0.9868	0.9871	0.9875	0.9878	0.9881	0.9884	0.9887	0.9890
2.3	0.9893	0.9896	0.9898	0.9901	0.9904	0.9906	0.9909	0.9911	0.9913	0.9916
2.4	0.9918	0.9920	0.9922	0.9925	0.9927	0.9929	0.9931	0.9932	0.9934	0.9936
2.5	0.9938	0.9940	0.9941	0.9943	0.9945	0.9946	0.9948	0.9949	0.9951	0.9952
2.6	0.9953	0.9955	0.9956	0.9957	0.9959	0.9960	0.9961	0.9962	0.9963	0.9964
2.7	0.9965	0.9966	0.9967	0.9968	0.9969	0.9970	0.9971	0.9972	0.9973	0.9974
2.8	0.9974	0.9975	0.9976	0.9977	0.9977	0.9978	0.9979	0.9979	0.9980	0.9981
2.9	0.9981	0.9982	0.9982	0.9983	0.9984	0.9984	0.9985	0.9985	0.9986	0.9986
3.0	0.9987	0.9987	0.9987	0.9988	0.9988	0.9989	0.9989	0.9989	0.9990	0.9990
3.1	0.9990	0.9991	0.9991	0.9991	0.9992	0.9992	0.9992	0.9992	0.9993	0.9993
3.2	0.9993	0.9993	0.9994	0.9994	0.9994	0.9994	0.9994	0.9995	0.9995	0.9995
3.3	0.9995	0.9995	0.9995	0.9996	0.9996	0.9996	0.9996	0.9996	0.9996	0.9997
3.4	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9998

Heute geht es auch schneller, zum Beispiel mit Python:

```
from scipy.stats import norm

print(norm.cdf(1.96))

# Berechnet die Fläche von links bis 1.96
```



DSI Data Science Institute

Normalverteilung - Beispiel



„Wie groß ist die Chance, ein Model-Maß zu haben?“

Angenommen, die Körpergröße X von Frauen in Deutschland ist normalverteilt mit:

- Mittelwert (μ): 166 cm
- Standardabweichung (σ): 6 cm

z	.00
.0	0.5000
.1	0.5398
.2	0.5793
.3	0.6179
.4	0.6554
.5	0.6915
.6	0.7257
.7	0.7580
.8	0.7881
.9	0.8159
1.0	0.8413
1.1	0.8643
1.2	0.8849
1.3	0.9032
1.4	0.9192
1.5	0.9332
1.6	.9452
1.7	9554
1.8	41
1.9	13
2.0	0.9772

Die Frage: Wie wahrscheinlich ist es, dass eine zufällig ausgewählte Frau größer als 178 cm ist?

Wir übersetzen unseren Wert 178 cm in die Standardnormalverteilung Z:

$$Z = \frac{X - \mu}{\sigma} = \frac{178 - 166}{6} = 2$$

Bedeutung: Eine Frau mit 178 cm ist exakt **zwei Standardabweichungen** größer als der Durchschnitt.

Jetzt schauen wir in der Z-Tabelle nach dem Wert für $Z = 2{,}0$. Das ist die Fläche unter der Kurve von links bis zum Wert 2.

DSI Data Science Institute

Normalverteilung - Beispiel



Die Tabelle gibt uns immer die Wahrscheinlichkeit für „kleiner oder gleich“ an ($P(X \leq 178)$).

Da wir aber wissen wollen, wer **größer** ist, rechnen wir:

$$P(X > 178) = 1 - P(X \leq 178) = 1 - 0{,}9772 = 0{,}0228$$

Ergebnis: Nur ca. 2,3% der Frauen in Deutschland sind größer als 178 cm.

z	.00
.0	0.5000
.1	0.5398
.2	0.5793
.3	0.6179
.4	0.6554
.5	0.6915
.6	0.7257
.7	0.7580
.8	0.7881
.9	0.8159
1.0	0.8413
1.1	0.8643
1.2	0.8849
1.3	0.9032
1.4	0.9192
1.5	0.9332
1.6	.9452
1.7	9554
1.8	41
1.9	13
2.0	0.9772

Data Science Institute

Normalverteilung - Beispiel

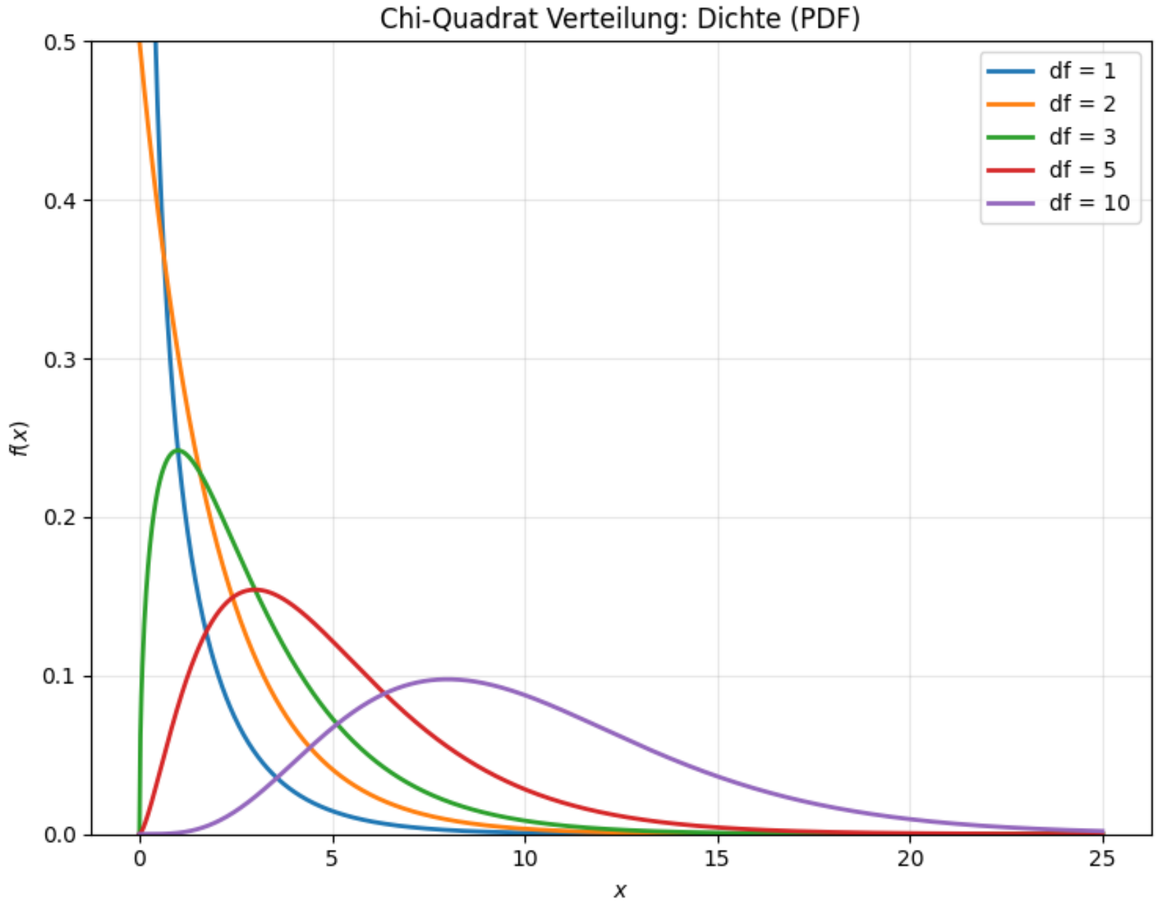


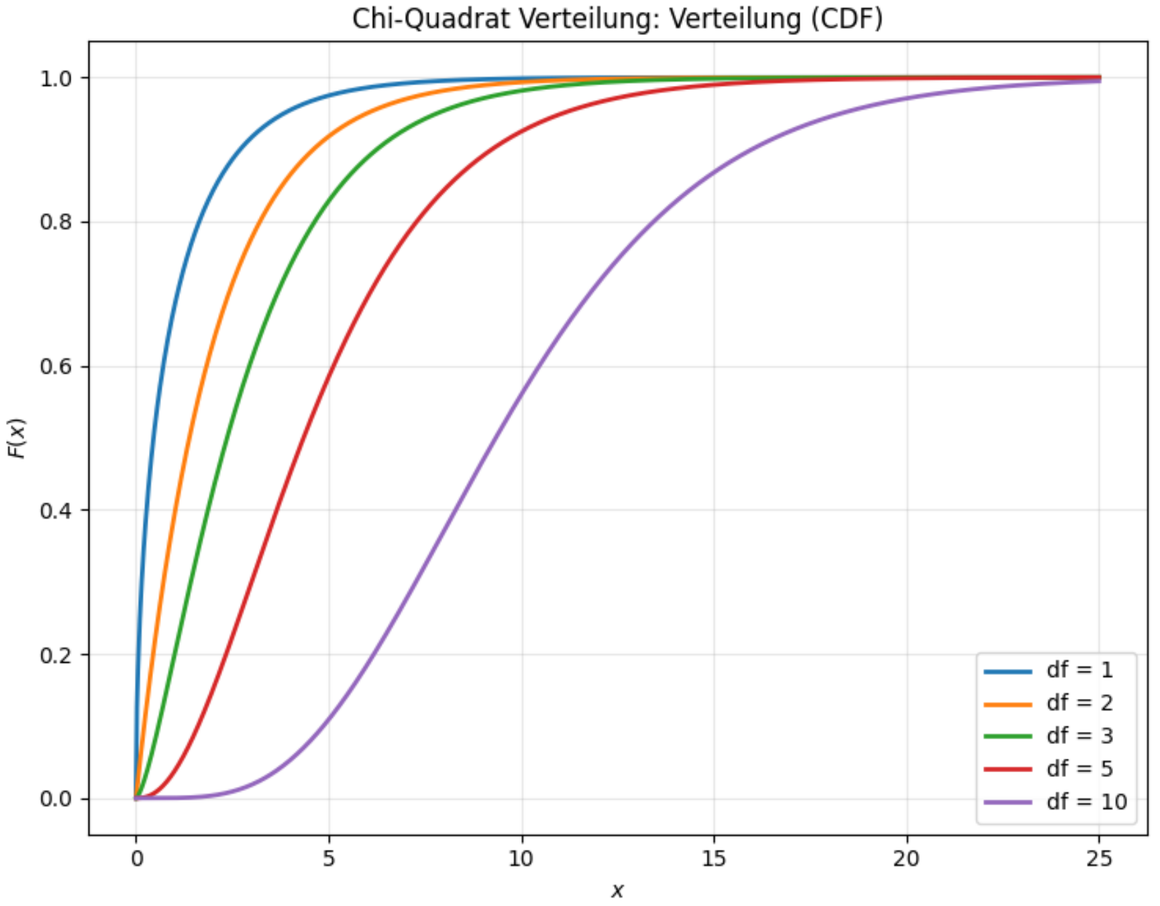

```
from scipy.stats import norm
# Parameter der Verteilung
mu = 166
sigma = 6
x_limit = 178

prob_less = norm.cdf(178, loc=166, scale=6)
print(f"Wahrscheinlickeit P(X <= 178): {prob_less:.4f}")


# Wahrscheinlichkeit P(X > 178) (Das Gegenereignis)
prob_greater = 1 - prob_less
print(f"Ergebnis (P > 178): {prob_greater:.4f} (entspricht {prob_greater:.2%})")
# Man kann die Werte auch direkt in die Funktion werfen.
prob_greater_direct = norm.sf(x_limit, loc=mu, scale=sigma) # sf = Survival Function
(1 - cdf)
print(f"Direkte Berechnung via Survival Function: {prob_greater_direct:.4f}")
```

Chi-Quadrat-Verteilung





DSI Data Science Institute

t-Verteilung



Die Story: Ein Brauer namens "Student"

Anfang des 20. Jahrhunderts arbeitete bei Guiness ein Chemiker namens **William Sealy Gosset**. Sein Job war es, die Qualität der Rohstoffe (Gerste, Hopfen) und des Biers zu überwachen.

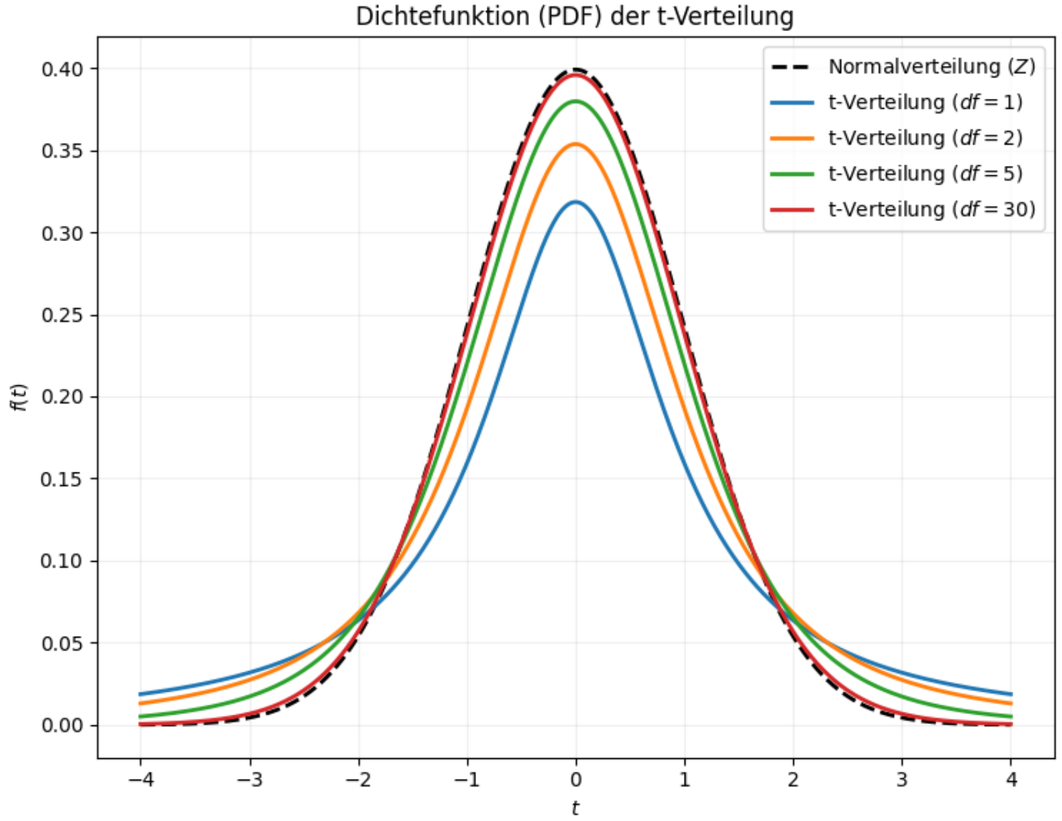
Das Problem: Gosset hatte oft nur sehr **kleine Stichproben** (z. B. nur 3 oder 5 Messungen einer Gerstensorte). Die normale Gauß-Glocke (Normalverteilung) funktioniert bei so wenigen Daten nicht gut, weil sie die Unsicherheit unterschätzt.

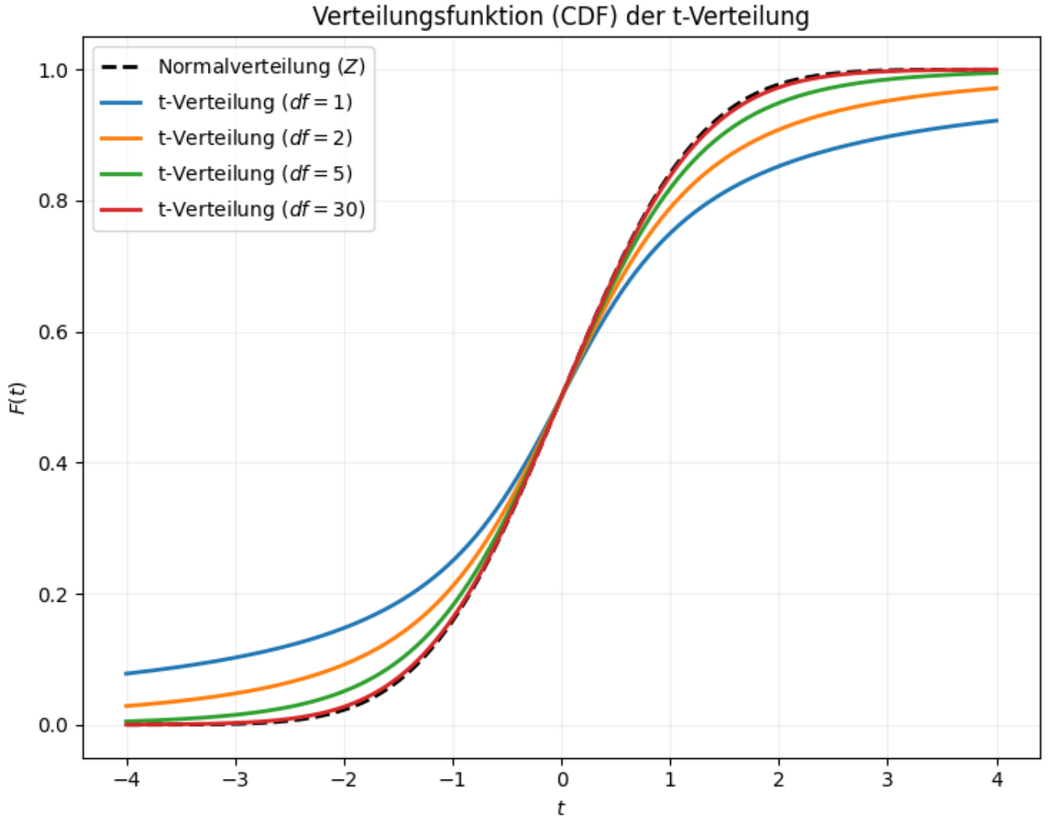
Die Lösung: Er entwickelte 1908 eine neue Verteilung, die bei kleinen Stichproben "breitere Ränder" (Fat Tails) hat, um das höhere Risiko von Ausreißern zu berücksichtigen.

Das Pseudonym: Guinness war extrem streng und verbot Mitarbeitern, Firmengeheimnisse zu veröffentlichen. Gosset durfte seine Entdeckung nur unter einem Decknamen publizieren. Er wählte schlicht: **"Student"**. Deshalb heißt sie heute noch **Student's t-Distribution**.

t-Verteilung







DSI Data Science Institute

t-Verteilung



Die t-Verteilung sieht der Normalverteilung sehr ähnlich, ist aber "flacher" und an den Seiten "dicker". Je mehr Daten du sammelst, desto mehr "schlankt" die t-Verteilung ab, bis sie irgendwann exakt so aussieht wie die Normalverteilung.

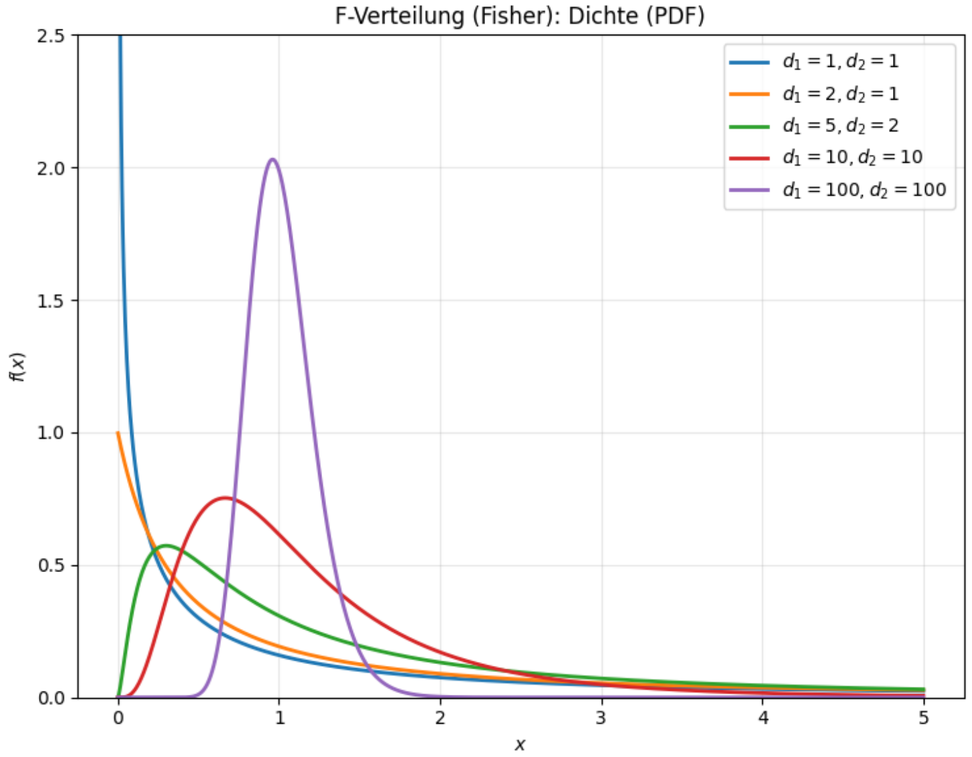
Warum war das für Bier wichtig?

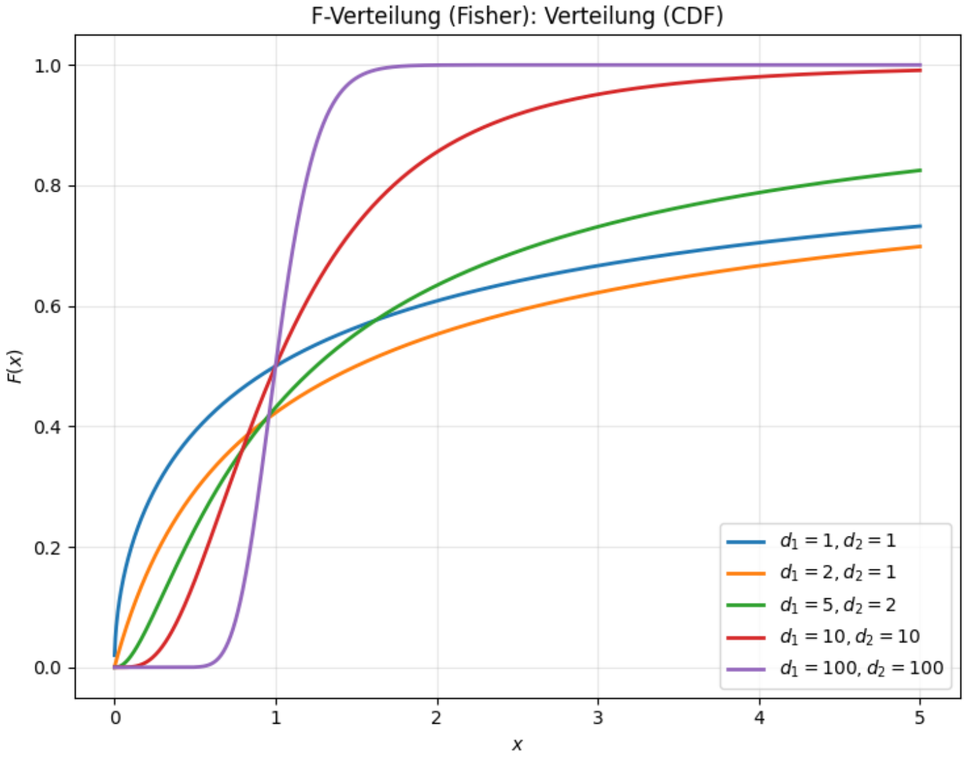
Wenn du 10.000 Liter Bier braust, willst du nicht erst 1.000 Liter testen müssen, um zu wissen, ob es schmeckt. Gosset ermöglichte es Guinness, mit minimalen Proben (Kostenersparnis!) wissenschaftlich präzise Aussagen über die Qualität des gesamten Suds zu treffen.



F-Verteilung

Ronald Fisher gilt als der „Vater der modernen Statistik“. Er war ein ziemliches Genie, aber auch bekannt dafür, sehr temperamentvoll zu sein. Die F-Verteilung wurde ihm zu Ehren von einem anderen Statistiker (Snedecor) so genannt – das „F“ steht also für Fisher!





DSI Data Science Institute

F-Verteilung



Die berühmteste Teestunde der Welt (The Lady Tasting Tea)

- Das ist die Geburtsstunde des modernen statistischen Testens. Eines Nachmittags in den 1920ern behauptete eine Kollegin (Muriel Bristol), sie könne am Geschmack erkennen, ob **zuerst der Tee oder zuerst die Milch** in die Tasse gegossen wurde.
- Die meisten hätten gelacht, aber Fisher war sofort im „Angriffsmodus“. Er organisierte auf der Stelle ein Experiment: Er bereitete acht Tassen vor (vier so, vier so). Er forderte sie heraus, die Tassen blind zuzuordnen.
- **Der Clou:** Muriel Bristol erkannte tatsächlich **alle acht** Tassen korrekt! Fisher war so beeindruckt (und vielleicht auch ein bisschen genervt, dass sie recht hatte), dass er daraufhin die gesamte Theorie der **Nullhypothese** entwickelte (in seinem Buch *The Design of Experiments* (1935)). Er wollte mathematisch beweisen, wie unwahrscheinlich es war, dass sie einfach nur Glück hatte.
- Ohne seinen Starrsinn und seinen Drang, jedem zu beweisen, dass er recht hat, hätten wir heute wahrscheinlich keine F-Verteilung und keine modernen Experimente. Er war eben ein „schwieriges Genie“.

t, χ, F

Wir haben uns gerade die t-**Verteilung**, die **Chi-Quadrat-Verteilung** und die **Fisher-Verteilung (F-Verteilung)** angeschaut.

Im Moment wirken sie vielleicht noch wie „nur ein paar weitere Graphen“. Aber keine Sorge: Wir haben heute nur mal kurz „Hallo“ gesagt, ohne direkt tief in die Berechnungen einzusteigen.

Diese Verteilungen sind sehr wichtig in der **Induktiven Statistik** (auch schließende Statistik genannt). Das ist der Teil, in dem wir nicht mehr nur beschreiben, was wir *sehen*, sondern Vorhersagen für die *ganze Welt* treffen wollen.