Statistik

Das Gesetz der großen Zahlen

DSI Data Science Institute

Inhaltverzeichnis

1. Einleitung

2. Das Gesetz der großen Zahlen

3. Der zentrale Grenzwertsatz

4. Fazit

Lernziele

- Das Gesetz der großen Zahlen erläutern und erklären, warum sich Stichprobenmittelwerte mit wachsendem Stichprobenumfang dem Erwartungswert annähern.

- Den Zentralen Grenzwertsatz beschreiben und verstehen, warum sich die Verteilung von Stichprobenmittelwerten bei großen Stichproben einer Normalverteilung annähert.

- Die Bedeutung von GGZ und ZGS für statistische Schätzverfahren, Konfidenzintervalle und Hypothesentests einordnen.

Einleitung - law of large numbers, central limit theorem

- Das ist quasi das "Finale" der Wahrscheinlichkeitstheorie. Wir schauen uns an, warum die Welt trotz all dem Chaos am Ende doch berechenbar ist.
- Das Gesetz der großen Zahlen (LLN, GGZ): Warum das Casino am Ende immer gewinnt, auch wenn du mal eine Glückssträhne hast. Es geht darum, wie sich der Durchschnitt bei vielen Versuchen stabilisiert.
- Der Zentrale Grenzwertsatz (CLT, ZGS): Das ist pure Magie. Er erklärt, warum fast alles in der Natur am Ende wie eine Normalverteilung aussieht, egal wie "wild" die Ausgangsdaten waren. Es ist der Grund, warum wir die Glockenkurve überhaupt so oft benutzen dürfen.

Das Gesetz der großen Zahlen

Für das arithmetische Mittel

$$\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$$

gilt dann für jedes beliebige $\epsilon > 0$:

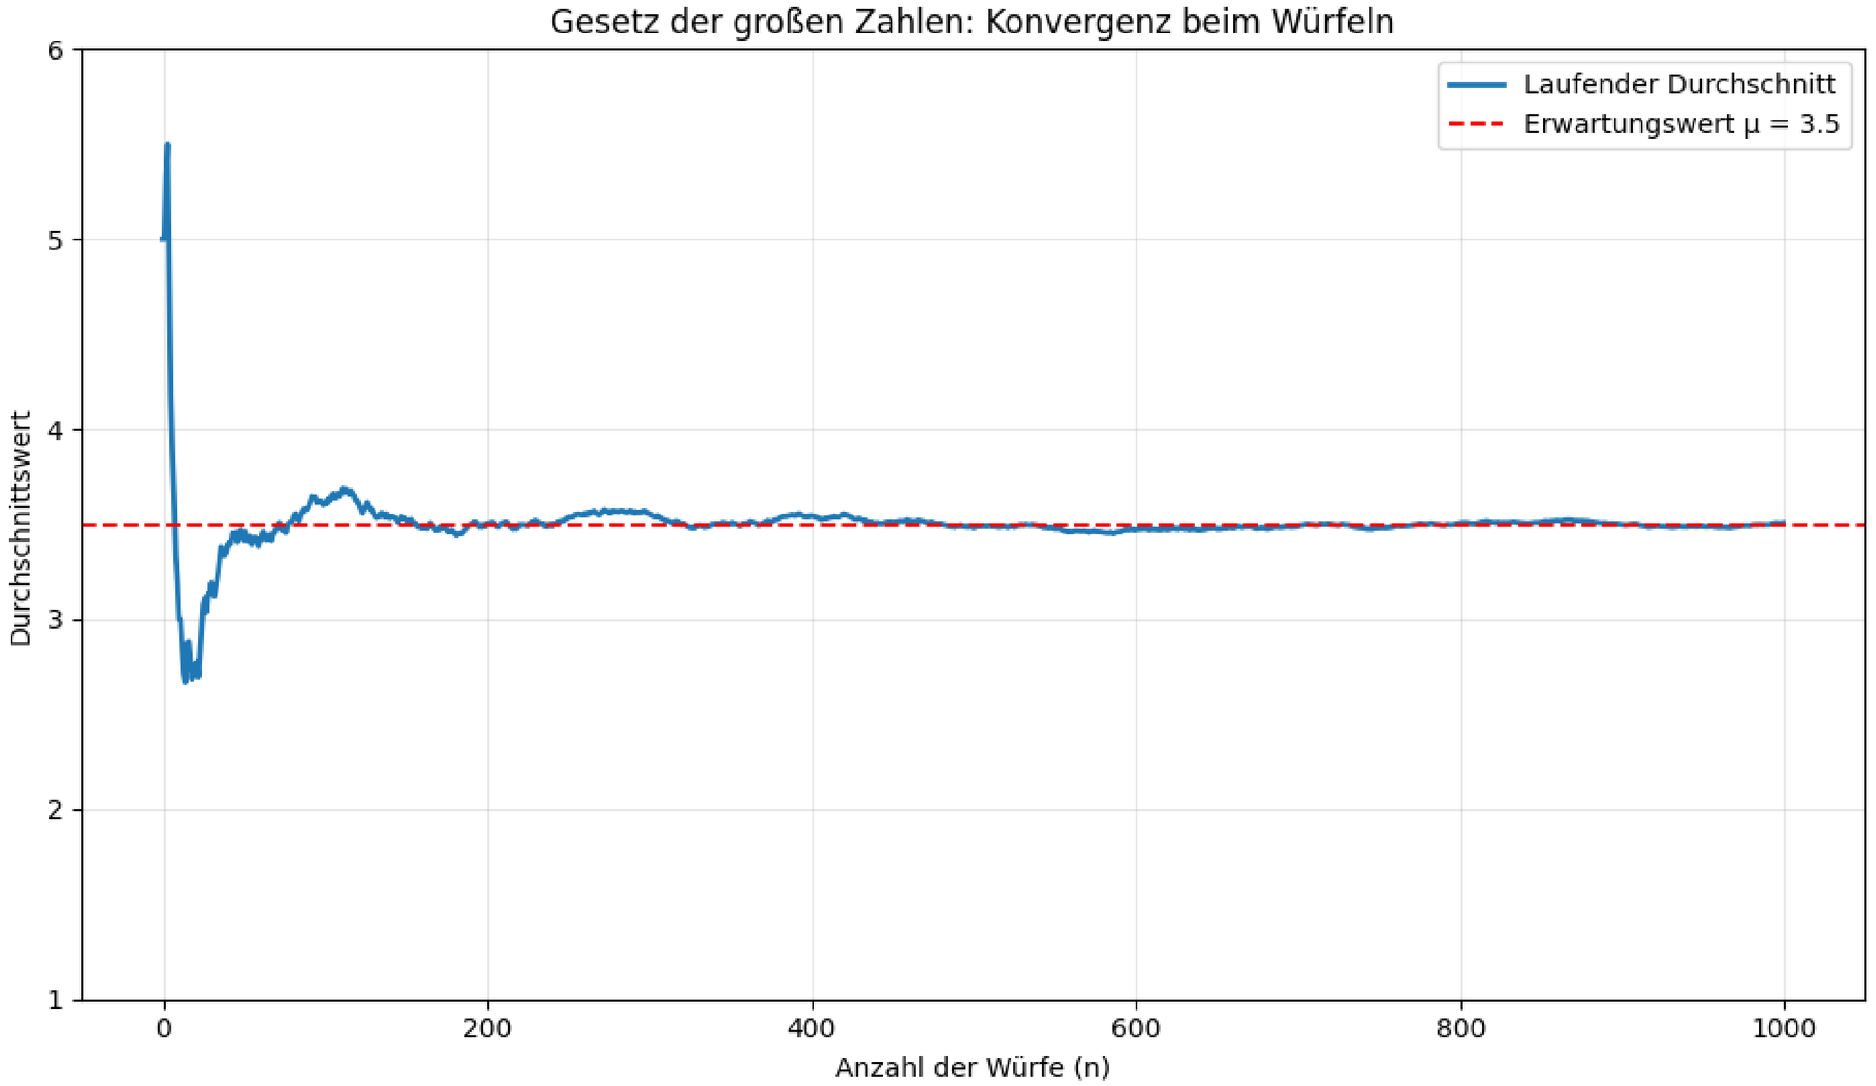
$$\lim_{n\to\infty} P(|\bar{X}_n - \mu| > \epsilon) = 0$$

Was das „auf Deutsch“ bedeutet:

Mit zunehmendem Stichprobenumfang ($n \to \infty$) nähert sich der Durchschnitt der Beobachtungen ($\bar{X}_n$) immer weiter dem tatsächlichen Erwartungswert (μ) an. Die Wahrscheinlichkeit, dass der berechnete Durchschnitt signifikant vom wahren Wert abweicht, geht gegen Null.

Es ist die mathematische Garantie, dass Zufall bei massenhafter Wiederholung verschwindet und durch Ordnung (den Mittelwert) ersetzt wird.

Das Gesetz der großen Zahlen - Beispiel Würfeln



DSI Data Science Institute

Das Gesetz der großen Zahlen - Beispiel Casino

Die Formel sagt eigentlich nur eins: **Einzelne Ereignisse sind Chaos, aber die Masse ist Ordnung.**

Beispiel:

- Wenn du eine Münze **10-mal** wirfst, ist es völlig normal, dass du 7-mal Kopf bekommst (70 %). Das ist purer Zufall.
- Wenn du die Münze aber **10.000-mal** wirfst, ist es fast unmöglich, dass du immer noch 70 % Kopf hast. Du wirst ganz nah bei den **50 %** landen.
- Je öfter du wirfst, desto mehr „fressen“ die vielen normalen Würfe die wenigen extremen Ausreißer auf.

Das Gesetz der großen Zahlen - Beispiel Casino

Warum das Casino immer gewinnt?

- Ein Spieler kann im Casino eine Glückssträhne haben und fett gewinnen. Das ist das „Chaos“ bei kleinen Zahlen.
- Das Casino spielt aber gegen tausende Menschen gleichzeitig (riesiges n).
- Das GGZ garantiert dem Casino, dass am Ende des Abends der Gewinn exakt dem mathematischen Erwartungswert μ entspricht – egal wie viel Glück der einzelne Spieler hatte.

Was das für die Statistik bedeutet:

Ohne dieses Gesetz könnten wir gar keine Umfragen oder Experimente machen. Wir vertrauen darauf, dass eine ausreichend große Stichprobe uns die **Wahrheit** (μ) über die gesamte Bevölkerung verrät.

Der Zentrale Grenzwertsatz

Seien $X_1, X_2, \ldots, X_n$ eine Folge von unabhängigen und identisch verteilten (i.i.d.) Zufallsvariablen mit dem Erwartungswert μ und einer endlichen Varianz $\sigma^2 > 0$. Für den standardisierten Durchschnitt Z_n gilt:

$$Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} N(0,1) \text{ für } n \to \infty$$

Was das „auf Deutsch“ bedeutet („Die Magie der Glockenkurve“):

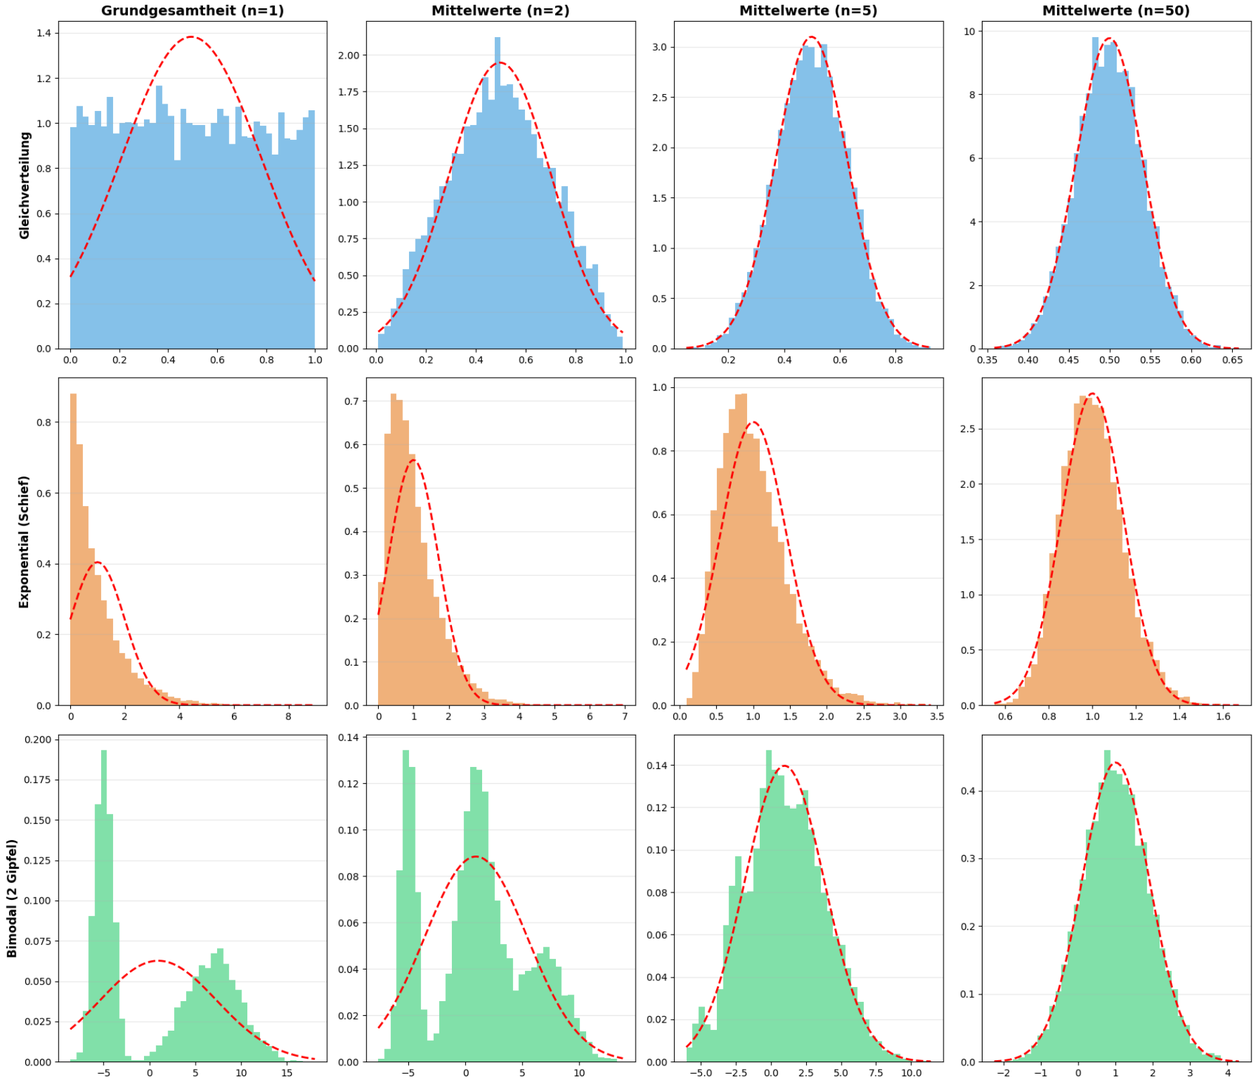
- Die Verteilung der Summe (oder des Durchschnitts) strebt gegen die **Standardnormalverteilung**.
- Egal, welche Form die ursprüngliche Verteilung deiner Daten hat (ob sie schief ist wie beim Einkommen, gleichverteilt wie beim Würfeln oder völlig chaotisch):
- Wenn du viele Stichproben ziehst und deren Mittelwerte berechnest, bilden diese Mittelwerte **immer** eine Normalverteilung (Glockenkurve).

Der Zentrale Grenzwertsatz - Beispiel

Die „Zähmung“ des Zufalls (Schritt für Schritt Einleitung)

- **Der Ursprung (Chaos):** Wir starten mit der **Stichprobe** $n = 1$. Das sind die „rohen“ Daten. Sie sind wild, schief, haben zwei Gipfel oder sind völlig flach. Hier gibt es **keine** Spur von einer Normalverteilung.
- **Die Stichprobe:** Wir ziehen aus diesem Chaos nicht nur einen Wert, sondern eine **Stichprobe** von n Werten (z. B. $n = 5$ oder $n = 50$).
- **Die Mittelwertbildung:** Wir berechnen den **Durchschnitt** dieser n Werte. Das ist der entscheidende Moment: Im Durchschnitt heben sich extrem hohe und extrem niedrige Werte gegenseitig auf.
- **Die Wiederholung:** Wir machen das nicht nur einmal, sondern **10.000-mal**. Wir sammeln also 10.000 verschiedene Durchschnitte.
- **Das Wunder:** Egal wie „hässlich“ die Daten in Schritt 1 waren – die Verteilung der Durchschnitte wird mit größerem n immer symmetrisch

Der Zentrale Grenzwertsatz - Beispiel



Data Science Institute

Der Zentrale Grenzwertsatz

- **Unkenntnis ist egal:** Wir müssen die ursprüngliche Verteilung der Grundgesamtheit gar nicht kennen. Wir wissen dank des ZGS, dass wir für den Durchschnitt trotzdem mit der Normalverteilung rechnen dürfen.
- **Die $n \geq 30$ Regel:** In der Praxis sagt man oft, dass ab einer Stichprobengröße von **30** die Normalverteilung eine sehr gute Annäherung ist, selbst wenn die echten Daten „wild“ aussehen. Der Zentrale Grenzwertsatz ist unsere „statistische Versicherung“.

Der Zentrale Grenzwertsatz

- **Beispiel klinische Studie:** Du testest ein neues Blutdruckmedikament an 200 Patienten. Die individuellen Blutdruckwerte einzelner Menschen sind oft nicht schön normalverteilt (Ausreißer, Schiefe etc.). Aber dank ZGS ist der **Mittelwert** der Blutdruckänderung über die 200 Patienten (bei ausreichend großem n) näherungsweise normalverteilt – **das** ermöglicht dir:
- **t-Tests / z-Tests:** "Ist die Blutdrucksenkung statistisch signifikant?"
- **Konfidenzintervalle:** "Die mittlere Senkung liegt mit 95% Sicherheit zwischen 8 und 12 mmHg."
- **p-Werte:** die Grundlage praktisch jeder Zulassungsstudie für Medikamente (FDA, EMA etc.)

Fazit

Wir schauen uns diese Sätze nicht nur aus Spaß an – sie sind das Fundament für alles, was wir in der **Induktiven Statistik** noch machen werden:

- **Bei den Schätzern:** Dank des **GGZ** wissen wir, dass unser Stichproben-Mittelwert ein „guter“ Schätzer für die echte Welt ist.
- **Bei den Hypothesentests:** Jedes Mal, wenn wir später einen z**-Test** oder t**-Test** machen, nutzen wir im Hintergrund den ZGS. Er erlaubt uns zu sagen: „Dieses Ergebnis ist so weit weg vom Durchschnitt, dass es kein Zufall mehr sein kann.“

Merksatz:

- Das **GGZ** sagt: „Du wirst am Ziel ankommen.“
- Der **ZGS** sagt: „Du wirst auf eine ganz bestimmte Art und Weise (normalverteilt) dort ankommen.“

Fazit

Gesetz der großen Zahlen (GGZ)

- **Jakob Bernoulli** bewies die erste Version — das **"schwache Gesetz der großen Zahlen"** — bereits um 1689–1705.
- **Pafnuti Tschebyschow** (1867): allgemeiner Beweis (braucht endliche Varianz).
- **Alexander Chintschin** (1929): noch allgemeinere Version (nur endlicher Erwartungswert). ★
- **Émile Borel** und später **Andrei Kolmogorov** (1933) etablierten das **"starke" Gesetz der großen Zahlen** in der modernen, maßtheoretisch strengen Form.

Zentraler Grenzwertsatz (ZGS)

- **Abraham de Moivre** bewies 1733 den **Spezialfall** für die Binomialverteilung (die Näherung durch die Normalverteilung bei großem n).
- **Pierre-Simon Laplace** verallgemeinerte das Ergebnis 1810–1812 erheblich und bewies eine viel breitere Version:
- Der **moderne, allgemeine Beweis** (für beliebige unabhängige, identisch verteilte Zufallsvariablen mit endlicher Varianz) stammt von **Alexander Ljapunow** (1901) ★
- **Jarl Waldemar Lindeberg** verallgemeinerte 1922 die Bedingungen weiter (die "Lindeberg-Bedingung" ist bis heute Standard in vielen Lehrbüchern).